



Mesures statistique et topologique d'un champ nuageux bidimensionel binaire

Rapport de stage présenté par

Jean GOUDOT

Stage effectué au

Laboratoire d'Optique Atmosphérique – UMR 8518

Sous la direction de

Olivier PUJOL

Le 28 août 2026 - Lille

Résumé

La description de la morphologie des nuages et leur classification est un enjeu important dans la compréhension de leur fonctionnement (auto-organisation, cycle de vie, conditions environnementales, propriétés radiatives). Cependant il n'existe à ce jour et à notre connaissance aucune mesure objective de la morphologie des champs nuageux. [Stevens et al. 2020] propose une classification subjective des structures des champs nuageux de l'Océan Indien, mais qui semble difficilement pouvoir trouver des applications dans les modélisations sous-maille, en sciences des données, ou encore faire le lien entre la structure macroscopique et les processus géophysiques en jeu. A l'issue de ce stage, nous sommes en mesure de proposer deux mesures de la morphologie des champs nuageux bidimensionnels, binaires. L'une – la fonction de corrélation – est de nature statistique. Les autres – les fonctionnelles de Minkowski, sont de nature topologique. L'universalité du problème de la description d'un champ bidimmensionnel binaire est au coeur de ce travail : l'enjeu était de parcourir la littérature de différents domaines, pour adapter les outils aux images satellites, et mettre en lumière les succès et limites qui leur sont spécifiques. Notre étude conclut à la nécessité d'approfondir la sensibilité des métriques à la résolution des images satellites pour exploiter pleintement leur potentiel scientifique.

Abstract

Describing cloud morphology and classifying clouds is a key challenge in understanding how they function (self-organization, life cycle, environmental conditions, radiative properties). However, to the best of our knowledge, there is currently no objective measure of cloud field morphology. [Stevens et al. 2020] proposes a subjective classification of cloud field structures in the Indian Ocean, but this classification appears unlikely to find applications in sub-grid-scale modeling, data science, or in establishing a link between macroscopic structure and the geophysical processes at play. At the conclusion of this internship, we are able to propose two measures of the morphology of two-dimensional, binary cloud fields. One—the correlation function—is statistical in nature. The other—the Minkowski functionals—is topological in nature. The universality of the problem of describing a two-dimensional binary field lies at the heart of this work: the challenge was to review the literature across various fields to adapt these tools to satellite imagery and highlight their specific strengths and limitations. Our study concludes that it is necessary to further investigate the sensitivity of these metrics to satellite image resolution in order to fully exploit their scientific potential.

Contents

1 Introduction **5**

2 Description statistique **7**
2.1 Introduction . . . 7
2.1.1 Définition . . . 7
2.1.2 Litterature . . . 8
2.2 Méthodes . . . 9
2.2.1 Fonction de corrélation numérique . . . 9
2.2.2 Image satellite . . . 10
2.3 Résultats et discussion . . . 10
2.3.1 Cas simples . . . 10
2.3.2 Analyse de sensibilité à la résolution . . . 13
2.3.3 Analyse de sensibilité au seuil . . . 13

3 Description topologique **16**
3.1 Introduction . . . 16
3.1.1 Définition . . . 16
3.1.2 Propriétés . . . 16
3.1.3 Littérature . . . 17
3.2 Méthodes . . . 20
3.2.1 Fonctionnelles de Minkowski numériques . . . 20
3.3 Résultats et discussions . . . 21
3.3.1 Effet de la résolution . . . 21
3.3.2 Effet du seuil . . . 22

4 Conclusion **26**

A Python code documentation **29**
A.1 `img` module . . . 29
A.2 `cloudfield` module structure . . . 29
A.2.1 Parameters . . . 29
A.2.2 Instance attributes . . . 30
A.2.3 Methods . . . 30

Notations

Notation	Dimension	Signification
c	1	Couverture nuageuse
S	1	Valeur du pixel de ciel, appelée *spin*
p	1	Notation générique pour une probabilité
$\vec{r}$, r, θ	L, L, 1	Position dans le voisinage d'un point, sa norme, son angle
$\vec{x}$	L	Position absolue dans le ciel
$\langle\cdot\rangle$	-	Opérateur de moyenne statistique
ℓ_c	L	Longueur de corrélation dans le modèle pseudo-exponentiel
B	1	Constante adimensionnée quelconque dans le modèle pseudo-exponentiel
X	-	Notation générique pour la partie de ciel nuageuse.
∂X	-	Interface entre la partie de ciel clair $\bar{X}$ et la partie nuageuse X
M_0	L^2	Fonctionnelle de Minkowski : surface nuageuse
M_1	L	Fonctionnelle de Minkowski : longueur d'interface
M_2	1	Fonctionnelle de Minkowski : courbure moyenne
χ	1	Caractéristique d'Euler, *i.e.* nombre de composantes connexes algébriques. $M_2 = \chi$
S_{tot}	L^2	Surface de l'image satellite
m_0	1	m_0 = couverture nuageuse c = normalisation M_0/S_{tot}
m_1	L^{-1}	Densité d'interface. Normalisation $m_1 = M_1/S_{\text{tot}}$
m_2	L^{-2}	Densité de composantes connexes. Normalisation $m_2 = M_2/S_{\text{tot}}$
s	L	Echelle de l'image satellite (km/px)
p_{m_i}	1	Fonction dérivée des m_i introduite par [Ouyang and Swinney 1991]
ρ	1	Seuil de binarisation

1 Introduction

Les rapport récents du GIEC [Douville et al. 2021] désignent les interactions vapeur-aérosols-nuages comme la source d'incertitude principale du bilan énergétique terrestre. Cela est dû d'une part à la complexité du phénomène, caractérisé par de nombreux degrés de liberté et des mécanismes non-linéaires, irréversibles et couplés. Les structures nuageuses que l'on peut observer à mésoéchelle sont une manifestation de cette complexité : on observe une grande variété de structures, qui apparaissent, disparaissent, se transforment sur des échelles de temps variables. La structure ou l'organisation de ces nuages dépend bien sûr des paramètres thermodynamiques environnants (humidité, température), des quantités et des tailles d'aérosols (noyaux de nucléation), mais aussi des changements d'état des nuages — condensation, précipitation ou évaporation. Ces changements d'état induisent eux-mêmes des flux thermiques et d'humidité, et constituent des rétroactions pouvant donner lieu à de l'auto-organisation [Mascaut et al. 2023, Sengupta et al. 1990, Wood 2012]. D'autre part, outre la complexité du phénomène, les propriétés radiatives des nuages en font un paramètre de sensibilité majeur du système climatique. Elles dépendent de l'altitude des nuages pour l'effet de serre et de leur épaisseur optique pour l'albédo.

Un enjeu de la recherche en sciences atmosphériques est donc de bien comprendre et modéliser les nuages. En particulier, il n'existe aujourd'hui aucune classification objective des structures nuageuses. [Stevens et al. 2020] a proposé une catégorisation subjective en quatre structures mésoéchelle ("fleurs", "sucres", "gravier" et "poisson", voir Figure 1), mais qui ne permet pas d'unification systématique de la diversité des structures. Les enjeux derrière la recherche d'un critère objectif, comme par exemple une *métrique* fondée sur divers paramètres physiques et statistiques (*e.g.*, surface, périmètre, longueur de corrélation, paramètre d'ordre, entropie, fonction de partition, etc.) sont de deux ordres. D'abord, réduire la dimensionnalité du problème, afin d'optimiser les ressources en calcul dans les modèles de climat en améliorant le réalisme des paramétrisations sous-maille. Ensuite, faire progresser notre compréhension des structures nuageuses en trouvant une classification explicite qui lie structures et conditions environnementales. À l'inverse, ce lien donnera accès à l'état de l'atmosphère, qu'il n'est pas toujours possible de mesurer directement, en particulier en présence de nuages.

Nous choisissons ici de considérer les champs nuageux sous le prisme de la physique statistique, et de leur appliquer les mêmes outils qu'à la matière condensée, ou aux systèmes thermodynamiques biphasés. Cette approche est encore largement sous-explorée, comme le conclut la revue [Singh and O'Neill 2022] sur la place de la seconde loi de la thermodynamique en physique du climat. Aussi nous considérons dans cette étude les champs nuageux comme un cas particulier de champ spatial à deux dimensions, à deux phases, dont on souhaite décrire la morphologie. D'autres travaux contemporains suivent cette voie : [Rees et al. 2024] introduit déjà quelques mesures objectives des champs nuageux, comme leur fractalité, en définissant une densité de périmètre $\mathcal{P}$. En calculant $\mathcal{P}$ pour plusieurs résolutions, il trouve une dimension fractale d'ensemble D_e.

L'exploration des sciences atmosphériques au moyen de la physique statistique est une approche récurrente dans l'œuvre d'Olivier Pujol. Le modèle le plus récent, dont le fonctionnement est détaillé dans [Mascaut et al. 2023], s'appelle BICIM – pour BIdimensional Cloud Ising Model. Le modèle d'Ising dont s'inspire BICIM est un des fondements de la physique statistique. Il a été développé par Ernest Ising et son directeur de thèse Wilhlem Lenz dans les années 1920, afin de modéliser les propriétés magnétiques des matériaux. Chaque atome interagit avec ses plus proches voisins et, selon la température, des comportements collectifs peuvent apparaître (milieu ferromagnétique à basse température) ou disparaître (milieu paramagnétique à haute température). [Mascaut et al. 2023] présente donc un modèle où le ciel, à altitude donnée, est divisé en cellules de 1 km $\times$ 1 km. Chaque cellule échange de l'énergie thermique, de la vapeur d'eau et des aérosols avec ses voisines et la surface par des flux diffusifs ou convectifs. Les valeurs de température, concentrations en vapeur d'eau et aérosols de chaque cellule sont comparées à une valeur seuil thermodynamique pour déterminer si la transition vers une cellule ciel clair ou nuageuse est possible. Les résultats de ce modèle sont très concluants quand on compare visuellement les observations MODIS/Aqua aux simulations (Fig. 2).

Notre étude s'inscrit dans le prolongement de celle de [Mascaut et al. 2023], pour répondre à la question scientifique suivante : *existe-t-il une métrique qui permette de classifier les structures nuageuses en fonction de leurs degrés d'auto-organisation, d'isotropie, etc. ?* Avec pour perspective une meilleure description de la transition de phase ciel clair / ciel nuageux, liée aux conditions environnementales.

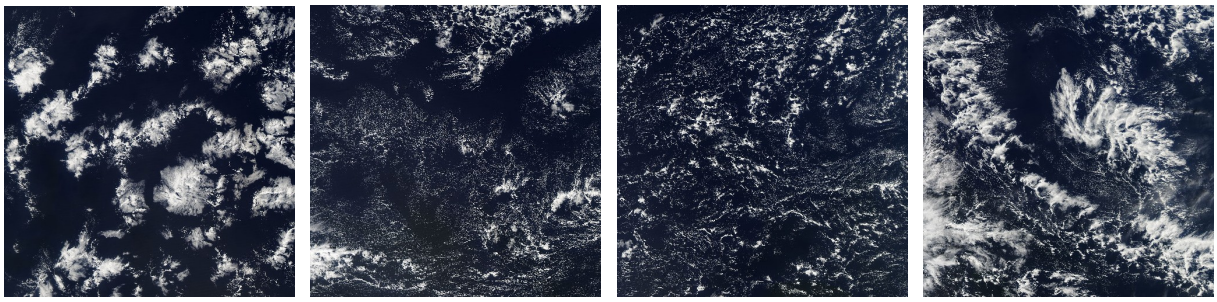


Figure 1: Classification des nuages de l'Océan Indien proposée par [Stevens et al. 2020]. De gauche à droite : "fleur", "sucre", "gravier", "poisson".

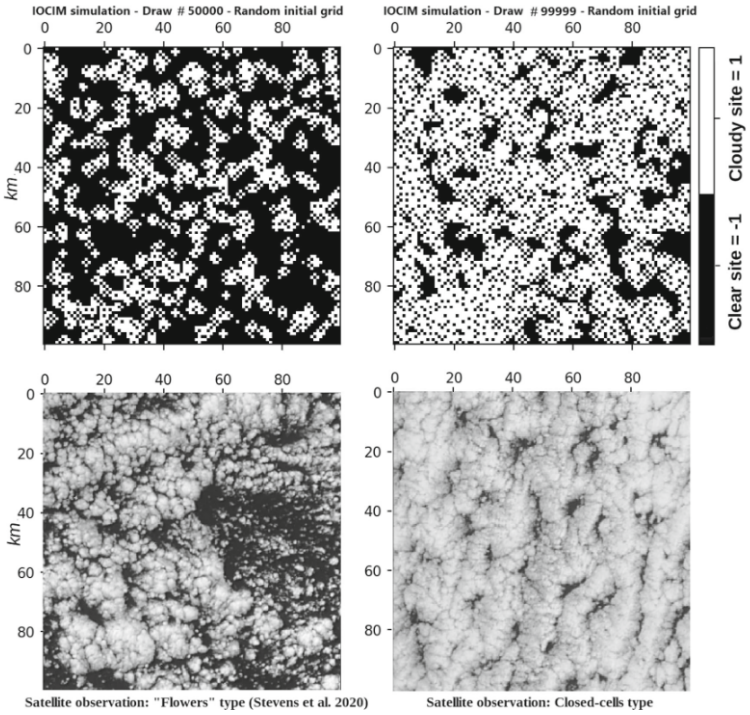


Fig. 7 Comparison of cloud fields generated by IOCIM from a random initial grid (top) with satellite observations (bottom) of "Flowers" type (on October, 23th 2022) and closed cells (on October, 12th 2022) over Indian Ocean

Figure 2: Comparaison visuelle entre une simulation BICIM (anciennement nommé IOCIM) et une observation MODIS/Aqua. (Tirée de [Mascaut et al. 2023]).

2 Description statistique

Dans cette première partie, nous présentons les fonctions de corrélation à deux points des champs nuageux. Après une courte introduction aux statistiques spatiales, nous définirons une fonction de corrélation $C(\vec{r})$ inspirée du modèle d'Ising. Nous calculerons cette fonction de corrélation pour différents cas simples, avant d'analyser sa sensibilité à la résolution, et au seuil de binarisation des images satellites. Nous introduirons par la même occasion une longueur de corrélation ℓ_c, échelle typique des structures d'un champ nuageux.

2.1 Introduction

2.1.1 Définition

Nous considérons ici le champ nuageux comme un champ bidimensionnel de *spin* $S(\vec{x})$, prenant des valeurs binaires selon que le ciel est nuageux ($S(\vec{x}) = +1$) ou clair ($S(\vec{x}) = -1$). [1] Nous étudions dans cette partie la statistique de ces champs, en particulier on fera intervenir des probabilités désignées de manière générique par la lettre p, comme par exemple la probabilité que le ciel soit nuageux en $\vec{x}$, $p(S(\vec{x}) = +1)$.

Le choix de binariser le champ, d'associer des valeurs de spin aux domaines du ciel , est motivé par la même analogie avec le ferromagnétisme quand dans [Mascaut et al. 2023]. [Sethna 2021] introduit une fonction de covariance pour décrire la structure microscopique des matériaux dans le modèle d'Ising, que nous nous réapproprions ici :

$$C(\vec{r}) = \langle S(\vec{x})S(\vec{x}+\vec{r})\rangle \tag{1}$$

où $\langle\cdot\rangle$ désigne la moyenne sur l'échantillon de ciel. Puisque $S(\vec{x})$ et $S(\vec{x}+\vec{r})$ valent ± 1, leur produit vaut ± 1, et C prend des valeurs comprises entre -1 et $+1$. On a par ailleurs toujours $C(\vec{r}=0) = +1$. Une dernière propriété immédiate est la symétrie de parité $C(\vec{r}) = C(-\vec{r})$ par le changement de variable $\vec{y} = \vec{x} + \vec{r}$.

Afin de mieux comprendre la fonction de corrélation C (aussi appelée fonction de covariance dans [Stoyan 2000]), on peut la décomposer selon la formule de l'espérance, puis selon les probabilités conditionnelles :

$$\begin{aligned}
C(\vec{r}) &= \langle S(\vec{x})S(\vec{x}+\vec{r})\rangle \\
&= \begin{array}{l} +1 \times p(S(\vec{x}) = +1 \cap S(\vec{x}+\vec{r}) = +1) \\ +1 \times p(S(\vec{x}) = -1 \cap S(\vec{x}+\vec{r}) = -1) \\ -1 \times p(S(\vec{x}) = -1 \cap S(\vec{x}+\vec{r}) = +1) \\ -1 \times p(S(\vec{x}) = +1 \cap S(\vec{x}+\vec{r}) = -1) \end{array} \\
&= \begin{array}{l} [p(S(\vec{x}+\vec{r}) = +1|S(\vec{x}) = +1) - p(S(\vec{x}+\vec{r}) = -1|S(\vec{x}) = +1)] \times p(S(\vec{x}) = +1) \\ +[p(S(\vec{x}+\vec{r}) = -1|S(\vec{x}) = -1) + p(S(\vec{x}+\vec{r}) = +1|S(\vec{x}) = -1)] \times p(S(\vec{x}) = -1) \end{array}
\end{aligned} \tag{2}$$

Ici, on fait apparaître des probabilités conditionnelles dont la signification est claire, *e.g.* $p(S(\vec{x}+\vec{r}) = +1|S(\vec{x}) = +1)$ – probabilité de trouver un point nuageux *voisin* d'une distance $\vec{r}$ d'un point nuageux *central* situé en $\vec{x}$. On reconnaît la couverture nuageuse et son complémentaire dans $p(S(\vec{x}) = \pm 1)$.

Enfin, on peut intégrer la fonction de corrélation spatiale $C(\vec{r})$ pour construire une fonction de corrélation radiale $C(r)$ qui donne la corrélation entre deux points séparés d'une distance r, ou une fonction de corrélation angulaire $C(\theta)$ qui donne la corrélation entre deux pixels séparés d'un angle θ. De la parité de la fonction de corrélation spatiale découle la périodicité de la fonction de corrélation angulaire $C(\theta) = C(\theta + \pi)$.

[1] Deux approches sont possibles pour modéliser la corrélation en statistique des surfaces. Soit on attribue des valeurs de spin $+1$ et -1 aux domaines nuageux et ciel clair respectivement, soit on privilégie les domaines nuageux et attribuant des valeurs de spin $+1$ et 0 aux domaines nuageux et ciel clair respectivement. La première fonction $C^{\mathrm{sym}}(\vec{r}) = C(\vec{r})$ renseigne sur la probabilité que le ciel soit identique pour deux points séparés d'un vecteur $\vec{r}$. La seconde fonction $C^{\mathrm{asym}}(\vec{r})$ renseigne quant à elle sur la probabilité que le ciel soit nuageux à une certaine distance $\vec{r}$ d'un point nuageux. Le choix de l'une ou l'autre des fonctions n'est pas évident, et nous choisissons de symétriser le ciel en cohérence avec le modèle d'Ising et avec la seconde partie sur les fonctionnelles de Minkowski.

2.1.2 Litterature

De nombreux domaines des sciences expérimentales sont confrontés à l'analyse de données spatiales, où la réduction d'une image à un nombre fini de paramètres n'est pas évidente. Les *statistiques spatiales* proposent des métriques, modèles pour décrire les structures dans l'espace, dont peuvent s'inspirer divers champs disciplinaires. Ces méthodes d'analyse ouvrent des possibilités de classification, de compréhension des phénomènes, de suivis temporels, de comparaison entre modèles et expériences. En particulier dans la continuité des travaux liés au modèle BICIM [Mascaut et al. 2023] qui vise à modéliser les champs nuageux de l'Océan Indien par le modèle d'Ising :

> *Physicists typically define models, calculate their physical properties and characterize the corresponding spatial structures. But they also have to face the 'inverse problem' of finding an appropriate model for a given spatial structure measured by an experiment. For example, if in a given situation an Ising model is appropriate, then the interaction parameters need to be determined (or, in terms of statistics, 'estimated') from a given spatial configuration. Furthermore, the goodness-of-fit of the Ising model for the given data should be tested. Fortunately, these are standard problems of spatial statistics, for which adequate methods are available.*
>
> (Klaus R. Mecke 2000)

Parmi les objets d'étude des statistiques spatiales, on distingue plusieurs types de champs : de points, de fibres, de surfaces. Les champs les plus étudiés sont les champs de points. Dans cette catégorie, on trouve l'étude de la répartition des galaxies dans l'univers [Richard, Pablo et al. 2025, Peebles 2020], des positions des molécules lors de transitions de phase [Bocquet 2023], des particules d'eau dans les nuages [Kostinski and Jameson 2000]. Remarquons que les objets modélisés par des points ne sont pas nécessairement ponctuels, et il est possible de décrire un phénomène physique par l'analyse du champ des centres de ces objets. Ainsi le modèle *germe-gains*, présenté section 3.1.3, associe à un champ de points (les germes) des objets de volume donné (les grains). Au contraire, les champs nuageux mésoéchelle se prêtent davantage à une description surfacique. Les outils pour décrire des champs de surface sont moins répandus que les champs de points, mais il est possible d'adapter certains outils statistiques des champs de points. Les statistiques spatiales étant construites pour l'étude des champs continus, il nous faudra également veiller à ce que la discrétisation de l'espace en pixels ne biaise pas le calcul ou l'interprétation des fonctions de corrélation.

Un cas particulier important de champ de points que nous adaptons aux champs de surfaces est le *champ poissonnien*. Il s'agit dans sa version originale d'une répartition homogène et indépendante de points dans l'espace, de densité λ. Le nombre de points dans un volume quelconque v suit alors une loi de Poisson de paramètre (λv), et la probabilité de trouver i points dans le volume v s'écrit :

$$p_v(i) = \frac{(\lambda\, v)^i}{i!}\, e^{-\lambda v} \tag{3}$$

Par analogie, nous définissions un champ de surface discret, que nous appelons *champ poissonnien* également, et où chaque pixel a une probabilité c d'être nuageux. [2] c correspond donc à la couverture nuageuse du champ. Nous considérons le champ poissonnien comme le cas de désorganisation maximale, où les pixels sont indépendants les uns des autres : nous tenterons ainsi au moyen des fonctions de corrélation de quantifier la *non-poissonnicité* des champs nuageux.

Enfin, deux propriétés importantes que doivent vérifier les images satellites que nous analysons sont l'*homogénéité*, *i.e.* l'invariance par translation dans l'espace, et l'*ergodicité*, *i.e.* l'équivalence entre la moyenne spatiale sur une image, et la moyenne locale sur les fluctuations aléatoires [Stoyan 2000]. Sans homogénéité, impossible de réduire le champ nuageux à quelques paramètres ; et l'ergodicité nous permet d'estimer certaines grandeurs statistiques à partir d'une image satellite instantanée. Ces deux propriétés ne peuvent être démontrées que pour des modèles statistiques. Aussi, on choisira des images satellites de champs nuageux visuellement homogènes, et on supposera l'ergodicité vraie, comme toujours en sciences expérimentales.

[2] En toute rigueur, le procédé numérique de production des champs aléatoires (tirage de Bernoulli de paramètre c pour chaque pixel) pourrait être qualifié de *binomial*. En effet, le nombre de pixels nuageux dans un volume quelconque v suit la loi binomiale $\mathcal{B}(N, c)$, où N est le nombre de pixels dans le volume. $N = v/a$ avec a le volume d'un pixel. Pour les ciels quasi-clairs, la loi binomiale tend vers la loi de Poisson de paramètre (Nc), et $\lambda \equiv c/a$.

Les fonctions de corrélation, dont une forme particulière a été introduite équation (1), trouvent une application particulière en physique de la matière condensée [Sethna 2021]. Le modèle d'Ising 2D, présenté en introduction, présente des domaines où les spins sont uniformément alignés dans l'état $|+\rangle$ ou dans l'état $|-\rangle$ (Fig. 3). [3]

Ainsi dans le cas des matériaux ferromagnétiques, la fonction de corrélation C se comporte de manière tout à fait différente selon que le système est à basse température ou haute température. La température qui sépare les deux comportements est appelée température de Curie T_c. A basse température ($T < T_c$), le matériau est dit *ferromagnétique*. Les deux domaines entrent en compétition, et le système brise la symétrie en choisissant une aimantation moyenne $m = \langle S(\vec{x})\rangle$ non nulle. L'aimantation m prend le signe des spins qui prédominent. La fonction de corrélation tend alors vers une valeur limite m^2 (Fig. 3, droite). Lorsque la température dépasse la température de Curie ($T > T_c$), le matériau est dit *paramagnétique*. Son aimantation moyenne est nulle, et sa fonction de corrélation tend vers 0. Dans les deux cas, la corrélation suit une décroissance exponentielle, et on peut définir à partir de cette tendance une *longueur de corrélation* ℓ_c. Enfin, à la température de Curie ($T = T_c$), les corrélations sont présentes à toutes les échelles, et la fonction C suit une loi de puissance. On ne peut alors plus définir de longueur de corrélation.

On notera une certaine similarité entre un champ nuageux mésoéchelle bidimmensionnel, binaire, et les simulations du modèle d'Ising (Fig. 3). Cette proximité apparente des deux systèmes, bien que très différents, justifie notre motivation à poursuivre l'analogie du modèle BICIM [Mascaut et al. 2023]. Nous appliquons donc la fonction de corrélation, dont l'importance vis-à-vis du modèle d'Ising vient d'être décrite, aux champs nuageux.

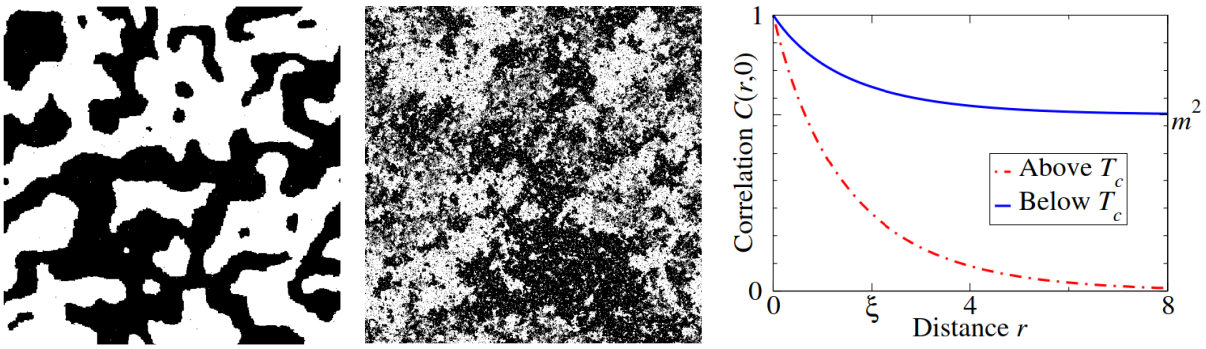


Figure 3: Figures tirées de [Sethna 2021, Chapitre 10]. A gauche, une simulation du modèle d'Ising à basse température ($T > T_c$). Au centre, une simulation du modèle d'Ising proche de la température de Curie ($T \approx T_c$). A droite, la calcul de la fonction de corrélation radiale $C(r)$.

2.2 Méthodes

2.2.1 Fonction de corrélation numérique

L'estimation de la fonction de corrélation à partir d'une image binaire suit l'algorithme représenté sur la Figure 4. La première étape est de tirer un nombre aléatoire de pixels *centraux* à l'intérieur de la fenêtre rouge, dont la signification est donnée au paragraphe suivant. Pour chaque pixel, on découpe un *voisinage* de taille $(r_{\max} + 1) \times (r_{\max} + 1)$. Ce voisinage de pixels nuageux blancs / ciel clair noirs est ensuite transformé en un voisinage de pixels corrélés rouges / anti-corrélés bleus avec le pixel central. Finalement, on moyenne l'ensemble de ces voisinages pour obtenir la fonction de corrélation spatiale $C(\vec{r})$. L'intégration de la fonction de corrélation spatiale pour obtenir les fonctions de corrélation radiale $C(r)$ et angluaire $C(\theta)$ se fait aisément.

L'application des concepts de statistiques spatiales à des images satellites ou à des simulations numériques nécessite de traiter les effets de bords. Le principe de la fonction de corrélation reposant sur l'analyse du voisinage des pixels, nous choisissons de nous affranchir des effets de bords en découpant une fenêtre à l'intérieur de laquelle sont tirés les pixels centraux. La taille de la marge de cette fenêtre rouge est déterminé par la taille du voisinage à sonder. On introduit donc la grandeur $r_{\max}$, rayon du

[3] Dans les matériaux réels, ces domaines existent, mais les aimantations peuvent prendre d'autres directions que haut ou bas. Ils sont appelés *domaines de Weiss*.

voisinage sondé pour chaque pixel central. Le choix de la valeur de $r_{\max}$ est un compromis entre la taille du voisinage à observer, et la taille de l'échantillon de pixels centraux au sein de la fenêtre. La gestion des effets de bords est discutée plus en détail dans [Stoyan 2000].

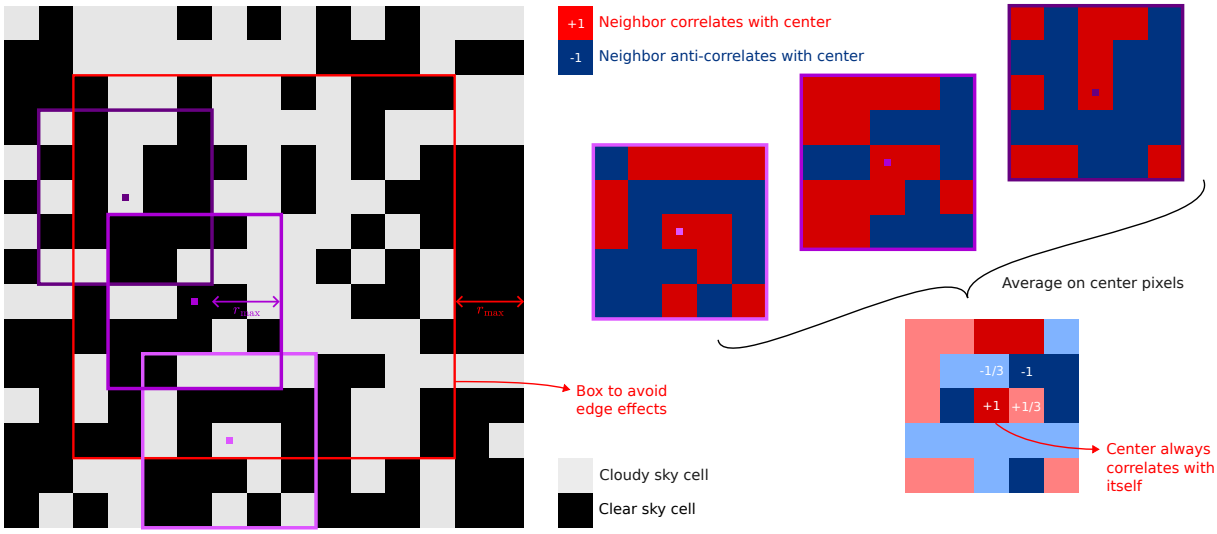


Figure 4: Fonction de corrélation numérique.

2.2.2 Image satellite

L'image satellite utilisée pour tester les fonctions de corrélation est issue de l'application NASA Worldview (https://worldview.earthdata.nasa.gov). L'outil de visualisation des nuages est une reconstruction RGB de ce que l'oeil humain verrait, à partir de trois bandes (I1, M4 et M3) du radiomètre visible-infrarouge VIIRS. Les bandes I ont une résolution de 375m, et les bandes M de 750m. L'instrument voyage à bord du satellite NOAA-20 lancé en 2017, qui suit une orbite quasi-polaire héliosynchrone. Il couvre la surface totale de la terre deux fois par jour.

2.3 Résultats et discussion

2.3.1 Cas simples

Dans cette partie nous analysons des cas simples de champs nuageux pour présenter les comportements attendus des fonctions de corrélation C. Sur la Figure 5, de haut en bas.

(1) Pour un champ nuageux quelconque, relativement isotrope, les fonctions de corrélation spatiale $C(\vec{r})$ et radiale $C(r)$ présentent des valeurs significativement élevées dans le voisinage immédiat du pixel central. La longueur de cohérence qui se dégage ainsi ($\sim$ 50 px) correspond à la taille caractéristique des structures nuageuses propres, *i.e.* les tailles *individuelles* des nuages. L'image présente une légère anisotropie à -10°, on voit en effet à l'œil nu que les champs nuageux sont préférentiellement quasi-horizontaux.

(2) Les rues de nuages sont un cas extrême d'anisotropie du champ nuageux. On perçoit clairement sur les fonctions spatiale $C(\vec{r})$ et radiale $C(r)$ la structure en franges, d'épaisseur $\sim$ 20 px, et qui garde une certaine cohérence même pour des portions de ciel situées à une distance de 100 px du pixel central. La fonction de corrélation angulaire $C(\theta)$ présente effectivement deux pics étroits situés à 40° et 220°. Ces deux valeurs correspondent aux deux angles que fait la direction privilégiée avec l'axe des abscisses ($220° = 40° + 180°$).

(3) Un champ parfaitement uniforme, parfaitement nuageux. Puisque pour tout $\vec{x}$, $S(\vec{x}) = +1$, le produit $S(\vec{x})S(\vec{x}+\vec{r})$ vaut $+1$, quel que soit $\vec{r}$. Le raisonnement est le même que le ciel soit parfaitement nuageux ou parfaitement clair.

(4) Un nuage rond de rayon 25 px dans un ciel clair. Les fonctions de corrélation spatiale $C(\vec{r})$ et radiale $C(r)$ mettent en évidence la contribution de la structure nuageuse propre pour les petits rayons $r < 50$ px. Au-delà de la taille caractéristique du disque, la corrélation se stabilise à 0.91. Cette valeur est le résultat de deux contributions. D'une part, les pixels nuageux sont anti-corrélés au voisinage lointain. Cette corrélation de -1 représente une part $2\pi\,(25\text{px})^2\,/\,(300\text{px})^2$ des pixels tirés au sort. D'autre part,

les pixels ciel clair sont presque toujours corrélés au voisinage lointain. Cette corrélation représente une part $[(300\text{px})^2 - 2\pi\,(25\text{px})^2]\,/\,(300\text{px})^2$. Finalement, au voisinage lointain, une moyenne pondérée donne $C = 1 - 4\pi(25\text{px})^2/(300\text{px})^2 = 0.91$.

(5) Un champ poissonnien de paramètre $c = 0.3$, c réprésentant donc la couverture nuageuse. Les pixels sont indépendants les uns de autres (à part $\vec{r} = 0$), et on a :

$$C = \langle S(\vec{x})\rangle\langle S(\vec{x}+\vec{r})\rangle = (2c-1)^2 \tag{4}$$

Une application numérique indique une corrélation poissonnienne théorique de 0.16, concordante avec la valeur moyenne de la corrélation spatiale simulée.

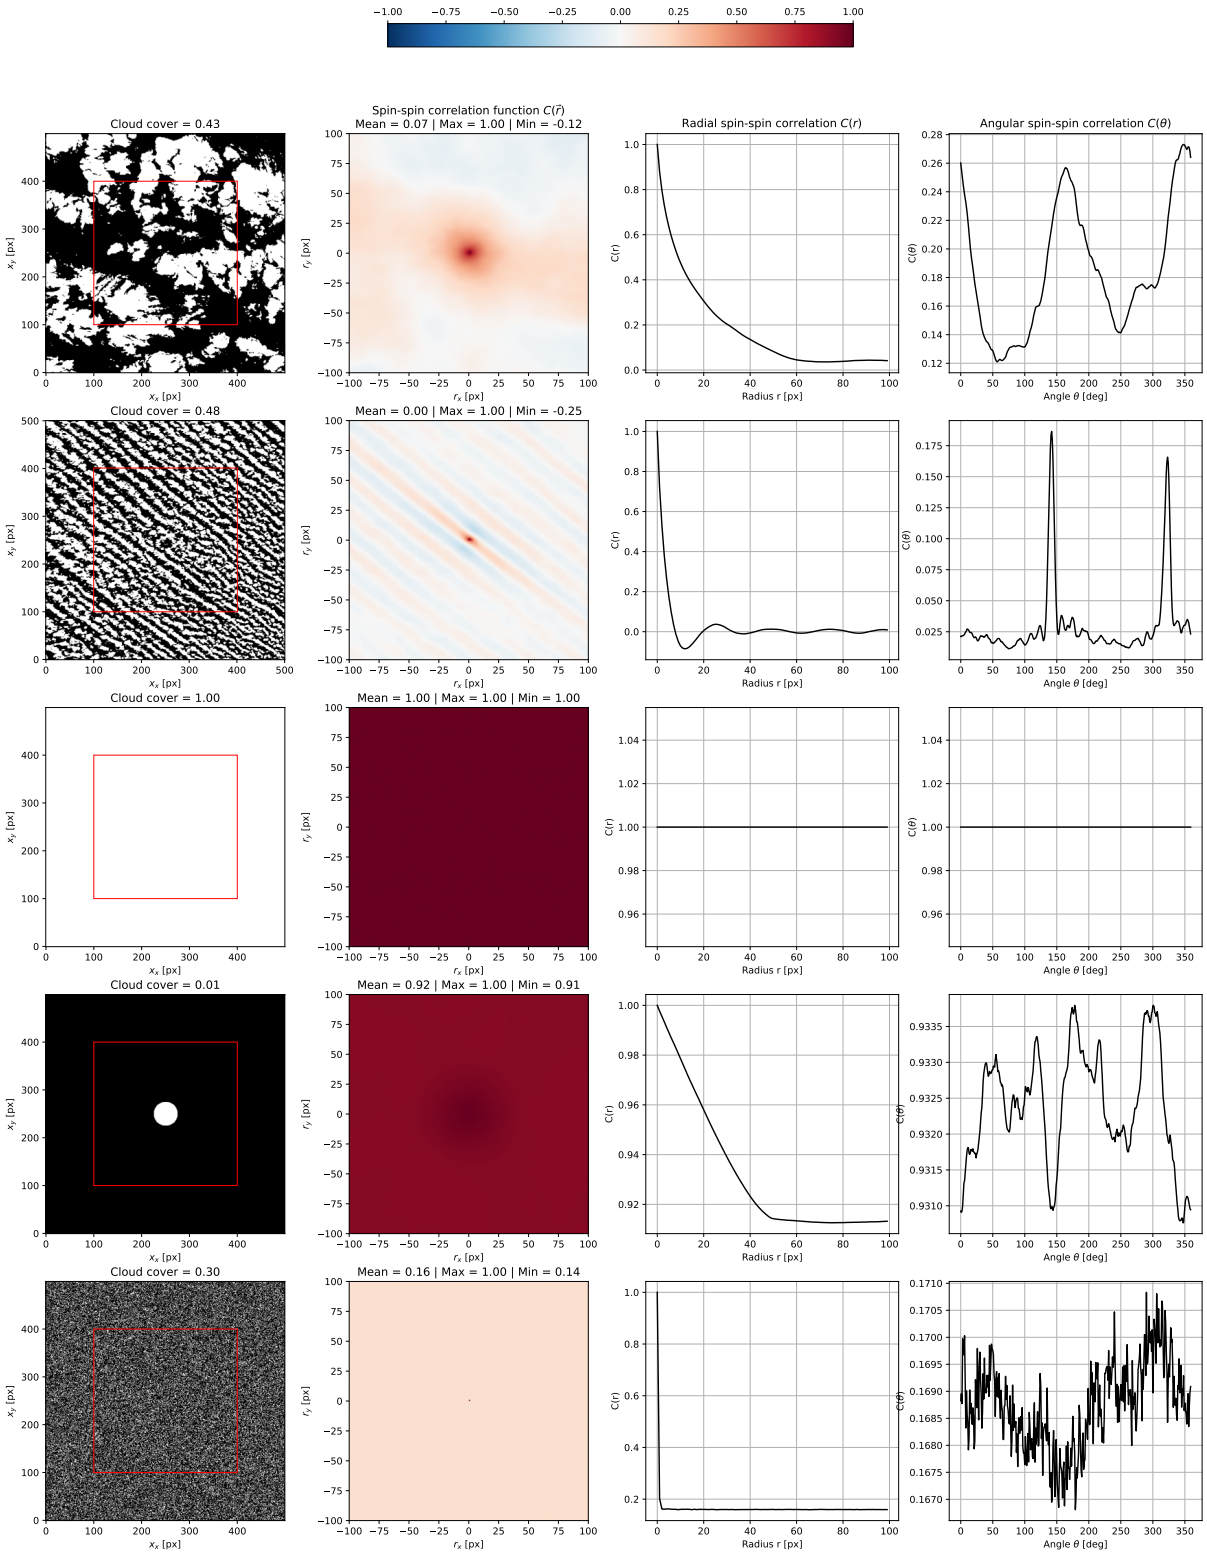


Figure 5: Calcul des fonctions de corrélation pour différentes structures nuageuses. De haut en bas : (1) un champ nuageux quelconque 500 m/px (NASA Worldview) ; (2) rues de nuages (NASA Earth Observatory) ; (3) ciel uniforme, parfaitement nuageux ; (4) disque de rayon 25 px ; (5) champ poissonnien. Les carrés rouges représentent les lieux de tirage des pixels centraux dans la gestion des effets de bord ($r_{\max} = 100$ px). Dans la fonction de corrélation angulaire $C(\theta)$, θ est l'angle par rapport à l'axe des abscisses, positif dans le sens trigonométrique.

2.3.2 Analyse de sensibilité à la résolution

Dans cette partie, nous allons évaluer la sensibilité de la fonction de corrélation radiale $C(r)$ à la résolution. Sur la Figure 6, une image optique de champ nuageux océanique est analysée selon plusieurs degrés de dégradation en résolution. A gauche, pour les pixels lointains ($r > 20$ km), les quatre courbes se superposent, ce qui indique une insensibilité de la fonction de corrélation radiale $C(r)$ à la résolution. Le proche voisinage ($r < 10$ km) est affiché à droite. On conserve cette insensibilité, bien que la résolution la plus grossière (courbe verte) semble manquer la statistique véritable du voisinage proche. En effet, le pas de discrétisation des rayons r est de l'ordre de la longueur de cohérence du champ nuageux.

2.3.3 Analyse de sensibilité au seuil

Nous allons maintenant évaluer la sensibilité de la fonction de corrélation radiale $C(r)$ au seuil de binarisation. Sur la Figure 7, la même image optique de champ nuageux océanique est analysée selon plusieurs valeurs de seuil. Contrairement à l'analyse de sensibilité en résolution, la corrélation est très sensible à la valeur de seuil. Cela était attendu, puisque déjà pour un champ poissonnien (constantes en pointillés colorés), nous avons montré [équation (4)] que la valeur de la corrélation est déterminée par la couverture nuageuse. Or la couverture nuageuse est elle-même directement reliée à la valeur du seuil choisie pour binariser l'image satellite.

Quelques comportements des fonctions de corrélation sont toutefois à noter.

(1) D'abord, sur le graphe en haut à gauche, les fonctions semblent converger en ordre de grandeur vers la corrélation équivalente champ poissonnien (constantes en pointillés colorés). En effet, on s'attend pour le voisinage éloigné à perdre toute cohérence et à retomber dans un comportement poissonnien.

(2) Ensuite, sur le zoom en haut à droite pour $r < 6$ km, on remarque que les fonctions de corrélations présentent toutes une décroissance pseudo-exponentielle en particulier pour le voisinage proche ($r < 3$km). Nous ajustons donc cette partie de la fonction de corrélation radiale $C(r < 3\,\text{km})$ sur le modèle empirique suivant :

$$r \mapsto \frac{e^{-r/\ell_c} + B}{1+B} \quad \begin{cases} \xrightarrow[r\to 0]{} & 1 \\ \xrightarrow[r\to+\infty]{} & \frac{B}{1+B} \end{cases} \tag{5}$$

où ℓ_c est une *longueur de corrélation*, et B une constante adimensionnée quelconque. Les résultats de l'ajustement de cette exponentielle décroissante sont consignés dans le tableau 1, et visualisables sur la figure 7. On remarque que les asymptotes du modèle se rapprochent elles aussi en ordre de grandeur de l'équivalent poissonnien. Les longueurs de corrélation sont d'ordre de grandeur comparable entre toutes les valeurs de seuil choisies. Ces résultats sont forts : ils permettent, dans une certaine mesure, de découpler l'effet de variation de la couverture nuageuse gloable, contenu dans B et relié à la corrélation poissonnienne, d'une caractéristique davantage reliée aux structures nuageuses qui est la longueur de corrélation. Il serait intéressant de comparer les valeurs de cette longueur de corrélation pour différentes images satellites, afin de savoir si elle permet de différencier plusieurs champs nuageux indépendamment du seuil de binarisation choisi.

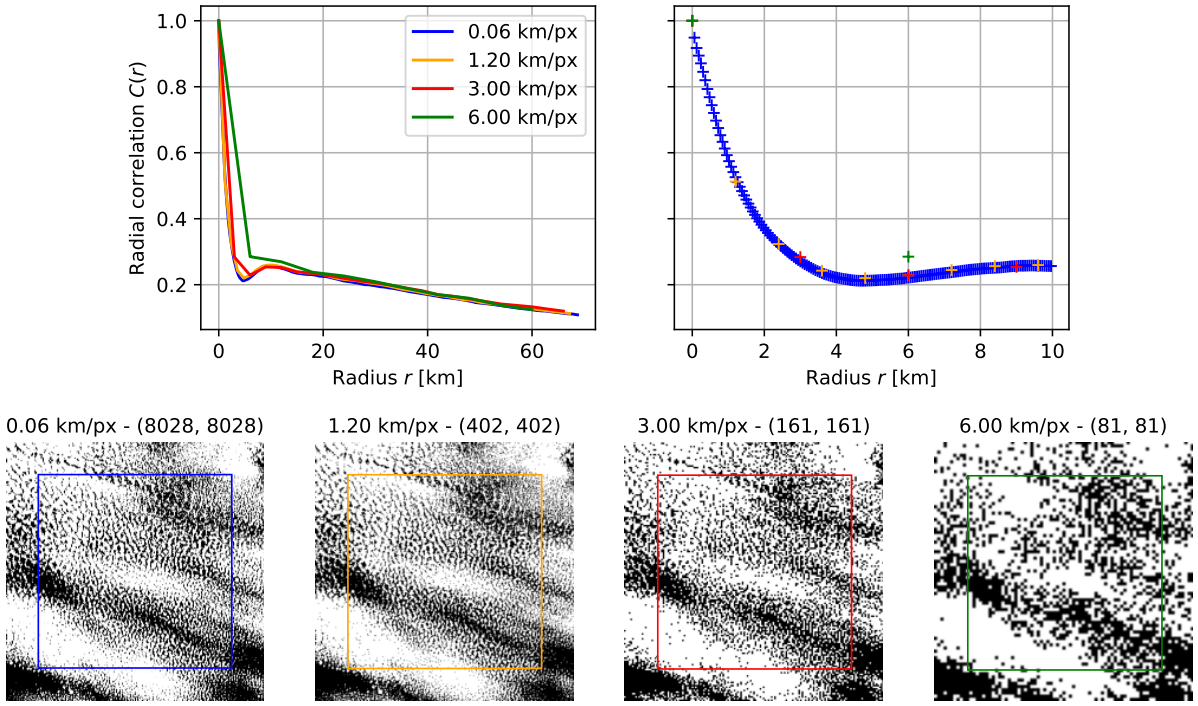


Figure 6: Analyse de sensibilité à la résolution d'une image satellite. Champ nuageux de l'Océan Indien observé par NOAA-20 / VIIRS (NASA Worldview). L'image originale (courbe bleue) a une résolution de 60 m/px. Elle est dégradée en ne gardant qu'un pixel sur 20 (orange), sur 50 (rouge), et sur 100 (verte). La valeur seuil est choisie à 150/255. Chaque fonction de corrélation est estimée à partir de 10^4 voisinages tirés aléatoirement. A droite, un zoom pour $r < 10$ km.

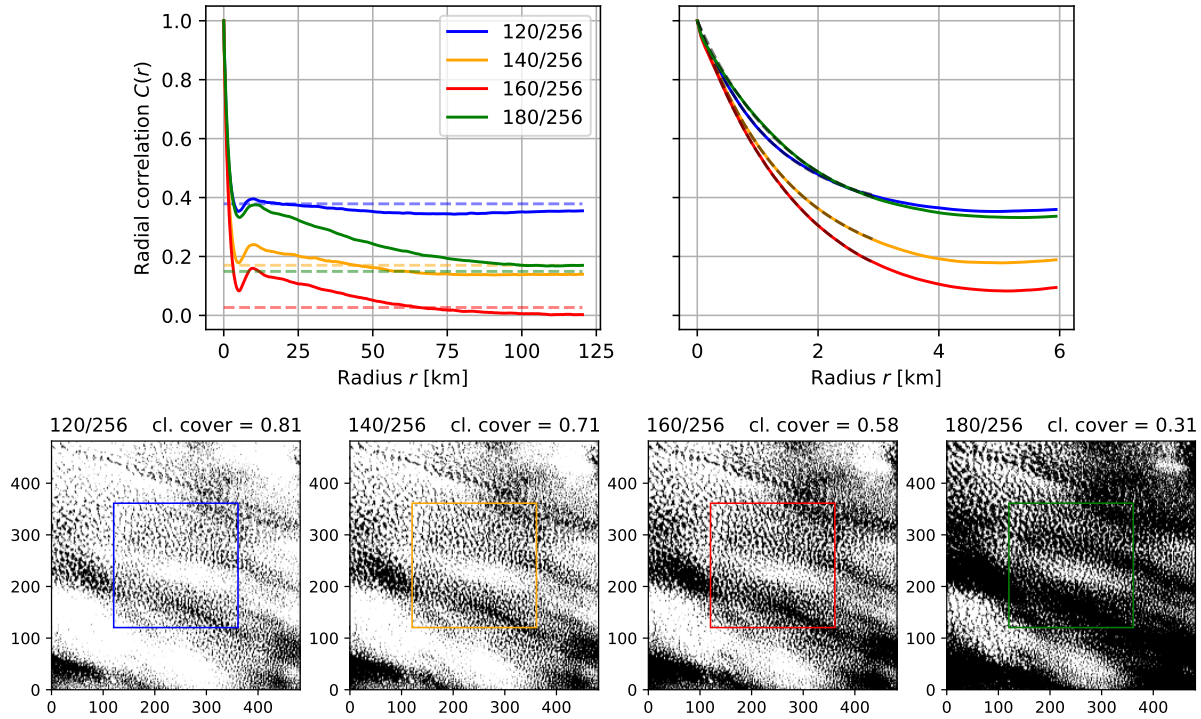


Figure 7: Analyse de sensibilité au seuil de binarisation d'une image satellite. Champ nuageux de l'Océan Indien observé par NOAA-20 / VIIRS (NASA Worldview), résolution de 60 m/px. Chaque couleur correspond à une valeur de seuil. En pointillés colorés sur les courbes en haut à gauche, la corrélation de l'équivalent poissonnien donnée par l'équation (4). En haut à droite, un zoom sur le proche voisinage $r < 6$ km, et l'ajustement d'un modèle exponentiel (5) en pointillés noirs, dont les paramètres sont listés dans le tableau 1. Chaque fonction de corrélation est estimée à partir de 10^4 voisinages tirés aléatoirement. Les axes des quatre images en bas sont en km.

Seuil	Couv. nuageuse c	Corr. Poisson	Longueur de corr. ℓ_c (km)	Asymptote $B\,/\,(1+B)$
120/256	0.81	0.38	1.22	0.33
140/256	0.71	0.17	1.49	0.14
160/256	0.58	0.027	1.62	0.026
180/256	0.31	0.15	1.49	0.29

Table 1: Synthèse des résultats de l'analyse de sensibilité au seuil (Figure 7). La corrélation poissonnienne est la valeur de corrélation obtenue pour un champ poissonnien de même couverture nuageuse [équation (4]. La longueur de corrélation ℓ_c et l'asymptote $B\,/\,(1+B)$ sont les paramètres d'ajustement de la fonction (5) sur la corrélation au voisinage proche ($r < 3$ km).

3 Description topologique

Dans cette partie, nous présentons les fonctionnelles de Minkowski. Ces grandeurs scalaires, au nombre de trois dans le cas d'un champ binaire bidimensionnel, sont issues du champ disciplinaire de la géométrie intégrale, et sont particulièrement bien adaptées à la description de la morphologie d'images numériques binaires. Elles ont déjà été utilisées pour décrire les micro-émulsions, la répartition des galaxies dans l'Univers, ainsi que la percolation des milieux poreux [K. R. Mecke 1996]. Bien que la question de classifier les champs nuageux selon leur morphologie soit une question largement abordée en physique des nuages [Stevens et al. 2020], leur étude sous l'angle des fonctionnelles de Minkowski n'est pas explorée à notre connaissance. Dans cette partie, nous tenterons de montrer le potentiel que présente l'introduction de variables macroscopiques issues des fonctionnelles de Minkowski pour d'une part classifier les structures nuageuses et, d'autre part, donner une lecture inspirée de la physique statistique des champs nuageux.

3.1 Introduction

3.1.1 Définition

Les fonctionnelles de Minkowski sont $(n+1)$ grandeurs scalaires qui caractérisent la morphologie d'une partie X d'un espace à n dimensions. Dans le cas d'un champ nuageux à deux dimensions, où X désigne la partie nuageuse, on pose :

$$M_0 = \int_X \mathrm{d}S \quad ; \quad M_1 = \int_{\partial X} \mathrm{d}\ell \quad ; \quad M_2 = \frac{1}{2\pi} \int_{\partial X} \frac{1}{R}\,\mathrm{d}\ell \tag{6}$$

M_0 correspond à la surface de la partie X, *i.e.* à la couverture nuageuse absolue. M_1 est la longueur totale de l'interface ∂X entre la partie nuageuse X et la partie ciel clair $\bar{X}$. M_2, sans dimension, est l'intégrale de la courbure $1/R$ (voir Figure 8) le long de l'interface ∂X. Les M_i sont les fonctionnelles de Minkowski [Klaus R. Mecke 2000].

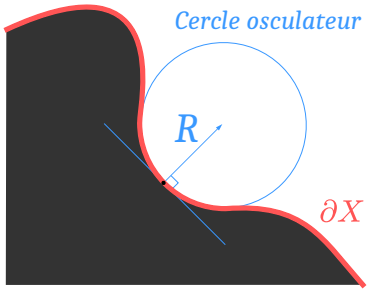


Figure 8: La courbure $1/R$ est l'inverse du rayon de courbure R, rayon du cercle osculateur pris en un point d'une courbe ∂X. Partie blanche : X, ou ciel nuageux. Partie noire : $\bar{X}$, ou ciel clair. Figure inspirée de Wikipédia.

Une autre introduction des fonctionnelles de Minkowski que la définition (6) est donnée dans [Eder 2018]. En 1840, le mathématicien Jakob Steiner montre que si on ajoute une couche arbitrairement fine – d'épaisseur ε – à un objet convexe X, alors le volume 3D de l'ε-*inflation* X_ε ainsi produite s'écrit :

$$M_0^{3D}(X_\varepsilon) = M_0^{3D}(X) + \varepsilon M_1^{3D}(X) + \varepsilon^2 M_2^{3D}(X) + \frac{4\pi}{3}\varepsilon^3 M_3^{3D}(X) \tag{7}$$

où les M_i^{3D} sont les fonctionnelles de Minkowski 3D, avec en particulier M_0^{3D} le volume, et M_1^{3D} la surface. Généralisons cet exemple au cas d'un disque 2D X de rayon a, sachant que $M_0 = \pi a^2$; $M_1 = 2\pi a$; $M_2 = 1$ d'après (6) :

$$\begin{aligned} M_0(X_\varepsilon) &= \pi\,(a+\varepsilon)^2 \\ &= \pi a^2 + 2\pi a\varepsilon + \pi\varepsilon^2 \\ &= M_0(X) + \varepsilon M_1(X) + \pi\varepsilon^2 M_2(X) \end{aligned} \tag{8}$$

3.1.2 Propriétés

Parmi toutes les mesures possibles d'un champ binaire, les fonctionnelles de Minkowski retiennent l'attention en raison de propriétés mathématiques pertinentes :

- D'abord, le théorème de Gauss-Bonnet relie la grandeur M_2 à la caractéristique d'Euler χ, différence entre le nombre de *nuages* N_{nuages}, *i.e.* composantes de ciel nuageux que l'on peut relier par un chemin, et le nombre de *trous* N_{trous}, *i.e.* composantes de ciel clair que l'on peut relier par un chemin (Fig. 9).

$$M_2 = \chi = N_{\text{nuages}} - N_{\text{trous}} \tag{9}$$

  Ce théorème nous permet de relier les notions intuitives de *nuages* et de *trous* sans jamais avoir besoin de morceller artificiellement la surface nuageuse X. La grandeur χ est aussi une propriété topologique du champ binaire, c'est-à-dire que sa valeur ne dépend pas de la taille ou de la forme des composantes de ciel nuageux ou de ciel clair, seulement de la connexité de ces parties du ciel. Un exemple bien connu d'invariance topologique est l'équivalence entre un donut et une tasse. La fonctionnelle de Minkowski M_2 prend des valeurs positives en présence d'un ciel clair avec quelques nuages épars, et prend des valeurs négatives pour un ciel nuageux avec quelques trous de ciel clair.

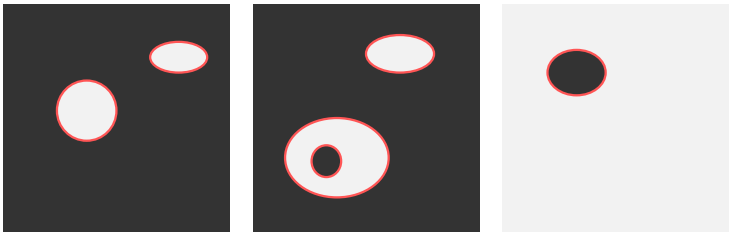


Figure 9: Exemples de caractéristiques d'Euler $\chi = N_{\text{nuages}} - N_{\text{trous}}$. Partie blanche : X, ou ciel nuageux. Partie noire : $\bar{X}$, ou ciel clair.

- Les fonctionnelles de Minkowski sont aussi *additives* [Armstrong et al. 2019] :

$$M_i(X_1 \cup X_2) = M_i(X_1) + M_i(X_2) - M_i(X_1 \cap X_2) \tag{10}$$

  Cette propriété, gage d'une certaine extensivité des fonctionnelles de Minkowski, nous conduit à proposer leur normalisation par la surface totale S_{tot} de l'espace de ciel, pour en faire des variables locales et intensives :

$$m_0 = \frac{M_0}{S_{\text{tot}}} \quad ; \quad m_1 = \frac{M_1}{S_{\text{tot}}} \quad ; \quad m_2 = \frac{M_2}{S_{\text{tot}}} \tag{11}$$

  $m_0 \in [0, 1]$, adimensionnée, correspond à la couverture nuageuse. $m_1 \geq 0$, inverse d'une longueur, correspond à la longueur d'interface par unité d'aire de ciel. $m_2 \in \mathbb{R}$, inverse d'une surface, correspond à la courbure par unité d'aire de ciel, ou au nombre de nuages moins nombre de trous par unité d'aire de ciel.

- Une dernière propriété remarquable des fonctionnelles de Minkowski est donnée par le théorème de Hadwiger [Armstrong et al. 2019]. Toute mesure $F(X)$ d'une partie X d'un espace d-dimensionnel s'écrit une comme une combinaison linéaire unique des $(d+1)$ fonctionnelles de Minkowski :

$$F(X) = \sum_{i=0}^{d} c_i \, M_i \tag{12}$$

  Cette propriété, montrant l'universalité des fonctionnelles de Minkowski – puisqu'on peut reproduire n'importe quelle mesure à partir d'elles, est probablement la raison principale pour laquelle ces grandeurs ont été largement employées pour décrire la morphologie des systèmes binaires. En particulier, [Klaus R. Mecke 2000] fait le lien entre les fonctions de corrélations à N points de le partie précédente et les fonctionnelles de Minkowski.

3.1.3 Littérature

Nous allons maintenant présenter quelques applications des fonctionnelles de Minkowski à travers différents champs disciplinaires.

Il existe une famille de réactions chimique de réaction-diffusion pour lesquelles le champ de concentrations en une certaine espèce chimique (ici l'ion I_3^-) s'auto-organise en trois types de motifs : hexagonal, lamellaire, turbulent (voir Figure 10) [Ouyang and Swinney 1991]. [K. R. Mecke 1996] est parvenu à décrire la morphologie du champ de concentration en ion I_3^- par 12 variables dérivées des fonctionnelles de Minkowski, qu'il est ensuite capable de relier aux paramètres expérimentaux (température, concentration des réactifs). L'un des enjeux de la construction de variables macroscopiques qui décrivent la structure du champ de concentrations, est de trouver un *paramètre d'ordre* qui décrit la transition de phase d'un type de structure vers un autre. Les *paramètres d'ordre* font référence à la théorie des transitions de phase de Landau, et ont permis une compréhension profonde et universelle des mécanismes phyiques qui sous-tendent les brisures de symétries associées à des transitions très variées (ferromagnétisme, changements d'état, etc.). Aussi l'une des variables construites dans [K. R. Mecke 1996] présente les caractéristiques d'un paramètre d'ordre dans la transition turbulent (le paramètre vaut 0) / hexagonal (le paramètre est non-nul) et invite à penser ces motif dans le cadre théorique des transitions de phase. La construction de ces variables est discutée plus en détail dans la section 3.3.2.

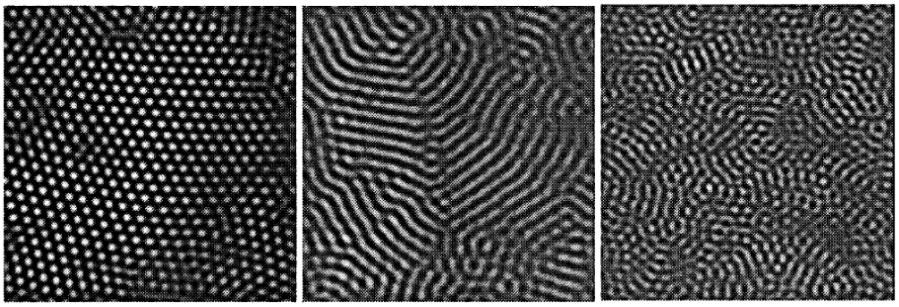


Figure 10: Trois types de motifs observés dans [Ouyang and Swinney 1991] : motif hexagonal (gauche), lamellaire (centre), et turbulent (droite). Les niveaux de gris correspondent à la concentration en ion I_3^-. Chaque image est constituée de 480×512 pixels, et échantillonnée en 256 niveaux de gris. Figure tirée de [K. R. Mecke 1996].

Une autre question des sciences expérimentales où les fonctionnelles de Minkowski ont apporté une perspective nouvelle, est celle du *démouillage*. Par exemple, le démouillage d'un film d'eau sur une surface cirée. Il s'agit dans l'article [Jacobs et al. 2000] de trancher la question de l'origine physique de la rupture de symétrie lorsqu'appararaîssent des *trous* secs dans le film liquide. Soit il s'agit d'un processus de *nucléation* à partir d'impuretés dans le substrat ou dans le liquide, soit il trouve son origine dans les fluctuations de l'épaisseur du film, qu'on appelle *démouillage spinodal*.

On notera que le type de structures qui se dessinent aux premiers instants d'un processus de démouillage est qualitativement assez différent des strutures nuageuses ou des motifs produits par la binarisation d'un champ continu de concentrations comme dans [K. R. Mecke 1996]. Là où les champs nuageux se décrivent par des statistiques de champs de surfaces, la morphologie de la partie sèche peut être décrite comme un ensemble de trous dans un modèle type germe-grain (voir section 2.1.2), et dont le rayon évolue avec le temps (voir Figure 11).

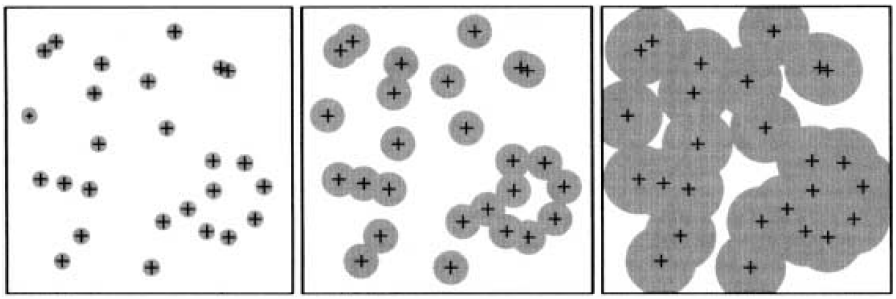


Figure 11: Les positions des trous, marquées d'une croix, sont décorées d'un disque dont le rayon augmente de gauche à droite. Figure extraite de [Jacobs et al. 2000].

Bien que dans le cas d'un film d'or liquide sur un substrat de quartz le démouillage spinodal –

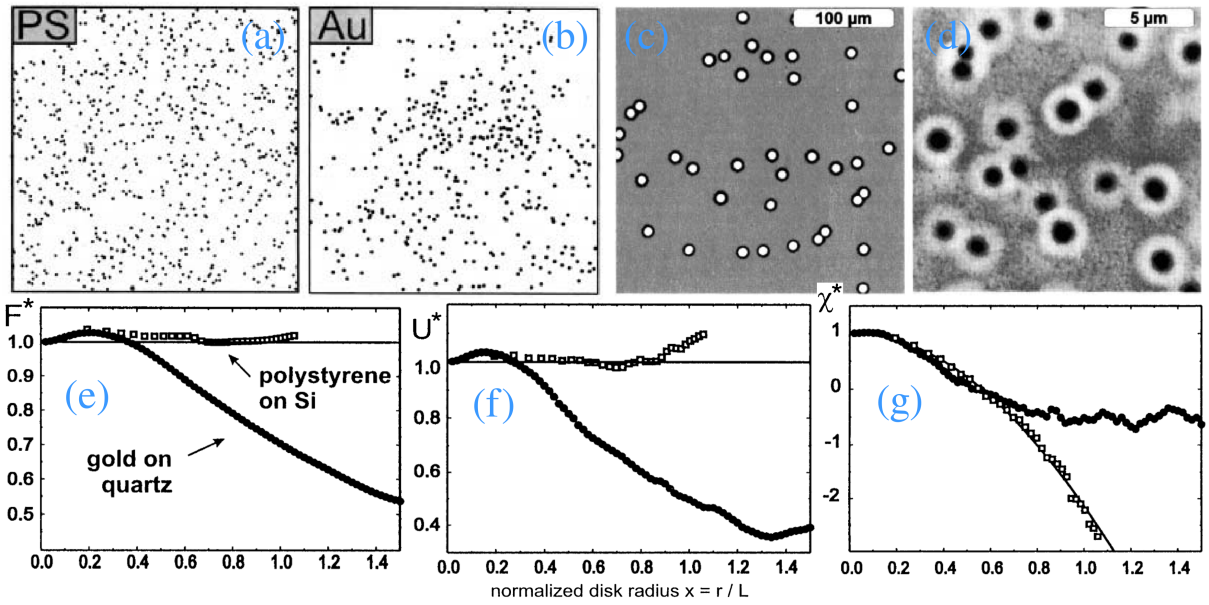


Figure 12: Figures empruntées à [Jacobs et al. 2000]. (a) Position des trous dans le film de polystyrène et (b) dans le film d'or. (c) Image au microscope optique d'un film de polystyrène de 60 nm sur une plaque silanisée. (d) Image Atomic Force Microscopy d'un film d'or de 100 nm sur une plaque de quartz. L'échelle des épaisseurs est représentée en niveaux de gris. (e, f, g) F^*, U^* et χ^* sont respectivement des normalisations de M_0, M_1, M_2 propres à l'article. En abscisse, le rayon des disques décorateurs (cf. Figure 11) est normalisé par la distance moyenne L entre les centres. Carrés : film de polystyrène. Disques : film d'or. Ligne continue : modèle poissonnien.

caractérisé par l'existence d'une longueur d'onde caractéristique $\lambda_{\max}$ – ait été mis en évidence dans de précédents travaux [Bischof et al. 1996], [Jacobs et al. 2000] montre qu'un calcul de fonction de corrélation de paire sur la position des trous est d'ordre trop faible pour pouvoir faire apparaître $\lambda_{\max}$. Une autre approche, basée sur les fonctionnelles de Minkowski, parvient à montrer une différence qualitative entre la distribution des centres des trous entre plusieurs dispositifs expérimentaux. En abscisse de la Figure 12, le rayon du disque "artificiel" qui décore la distribution expérimentale des centres des trous. La ligne continue correspond à une distribution poissonnienne des centres des trous. On peut désormais identifier le processus de démouillage : par nucléation pour le film de polystyrène sur une plaque silanisée (distribution Poissoninne des centres) ; spinodal pour le film d'or sur une plaque de quartz (corrélations dûes aux ondulations de l'épaisseur du film). Enfin, [Jacobs et al. 2000] conduit une étude dynamique de la croissance des trous en calculant les fonctionnelles de Minkowski pour chaque image d'un film de démouillage (Figure non inclue dans le présent rapport).

L'expérience précédente se rapproche du cadre théorique du *modèle booléen*, cas particulier des modèles *germe-grain*, et dont les première études datent du début du XXe siècle [Stoyan 2000, Wikipedia 2026]. Dans ce modèle, on tire un ensemble de germes $\mathbf{r_1}$, $\mathbf{r_2}$, ... selon une statistique poissonnienne (cf. 2.1.2). Les grains sont un ensemble de formes géométriques aléatoires $\{K_n\}_n$, par exemple des disques de tailles aléatoires (voir Figure 13). Dans ce cas, on a :

$$X = \bigcup_n (\mathbf{r_n} + K_n) \tag{13}$$

On voit bien, avec ces deux exemples en chimie et en physique, que les fonctionnelles de Minkowski ont beaucoup à apporter lorsqu'il s'agit de décrire la morphologie d'une imagine binaire, ou binarisée, quelle que soit la discipline. Nous aurions aussi pu détailler leurs applications en médecine afin de caractériser la réponse morphologique de cellules tumorales à un traitement [Larkin et al. 2014] ; la forme des nuages par l'introduction de deux paramètres dérivés des fonctionnelles de Minkowski 3D, *planarité* et *filamentarité* [Denby et al. 2022] ; ou encore la percolation d'un fluide à travers un milieux poreux [Armstrong et al. 2019].

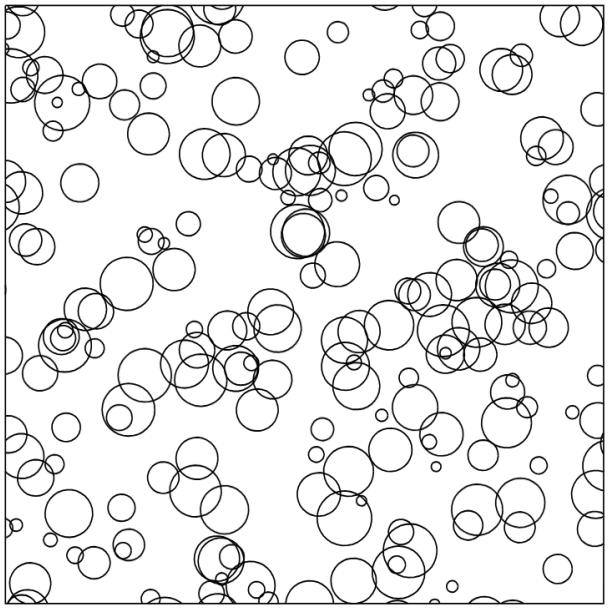


Figure 13: Simulation d'un modèle booléen où les grains sont des disques de tailles aléatoires. Figure empruntée à [Stoyan 2000].

3.2 Méthodes

Si les fonctionnelles de Minkowski constituent une approche intéressante pour caractériser les champs nuageux, elles ont toutefois été développées dans le cadre de la géométrie intégrale où l'espace est continu. Il est donc important de s'assurer de la robustesse de ces métriques par rapport à la discrétisation des champs nuageux. D'une part, la discrétisation dans l'espace, puisque les satellites fournissent des images pixellisées des champs nuageux. D'autre part, au moment de la binarisation, puisque les fonctionnelles de Minkowski décrivent des champs binaires.

3.2.1 Fonctionnelles de Minkowski numériques

Pour calculer les fonctionnelles de Minkowski sur les champs nuageux, nous avons utilisé DPM Tools, un paquet Python développé par le groupe de Digital Porous Media de l'Université du Texas, Austin.

Le fonctionnement des algorithmes de calcul des fonctionnelles de Minkowski sur des images numériques est détaillé dans [Armstrong et al. 2019]. Il s'agit pour chaque pixel de découper un bloc de 2×2 pixel voisins. On dénombre alors $2^4 = 16$ combinaisons de couleurs possibles pour chaque bloc, attribuables aux six cas présentés Figure 14 par rotation des blocs.

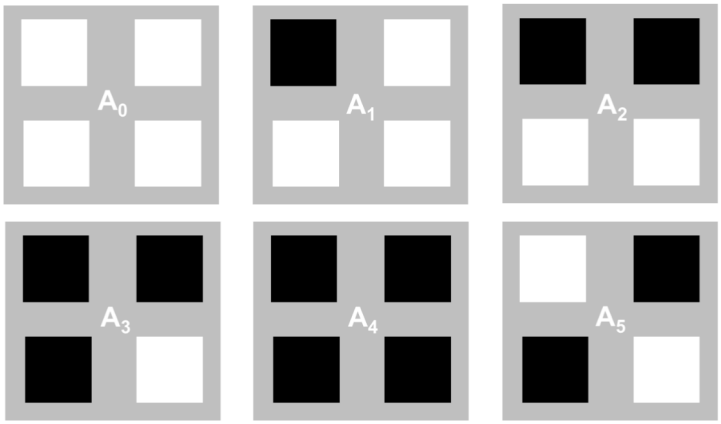


Figure 14: Six configurations isotropiques sont possibles pour des blocs de 2×2 pixels dans une image binaire 2D. La région en gris clair représente la fenêtre d'observation, les pixels noirs valent 0, et les pixels blancs valent 1. Figure empruntée à [Armstrong et al. 2019].

On compte ensuite le nombre N_{A_i} de blocs dans chaque catégorie A_i pour en déduire les fonctionnelles de Minkowski (cf. Figure 15) :

$$\begin{aligned} M_0 &= (N_{A_3} + 2N_{A_2} + 3N_{A_1} + 4N_{A_0} + 2N_{A_5}) \,/\, 4 \\ M_1 &= N_{A_3} + N_{A_2} + N_{A_1} + 2N_{A_5} \\ M_2 &= (N_{A_3} - N_{A_1} + 2N_{A_5}) \,/\, 4 \end{aligned} \tag{14}$$

Si le pixel d'ancrage des blocs de 2×2 est en haut à gauche, la question des bordures droite et inférieure se posent. Dans le package DPM tools que nous utilisons, ces deux lignes sont prises en compte en tant que voisinages, mais pas en tant que points d'ancrage (Fig. 15). L'effet de ce biais est toutefois limité si on néglige le poids de deux rangées de pixels par rapport à l'image totale.

On peut également se poser la question de la connexité : dans le cas A_5 les pixels sont considérés comme séparés et la caractéristique d'Euler M_2 vaut 2, quand on pourrait considérer que les deux pixels blancs font partie du même nuage. Il y a donc un choix à faire dans la définition de la connexité au moment de la discrétisation. Il serait intéressant d'étudier le comportement de la fonctionnelle M_2 quand on considère deux pixels diagonaux comme connexes, et de comparer les résultats avec la méthode de calcul classique utilisée ici.

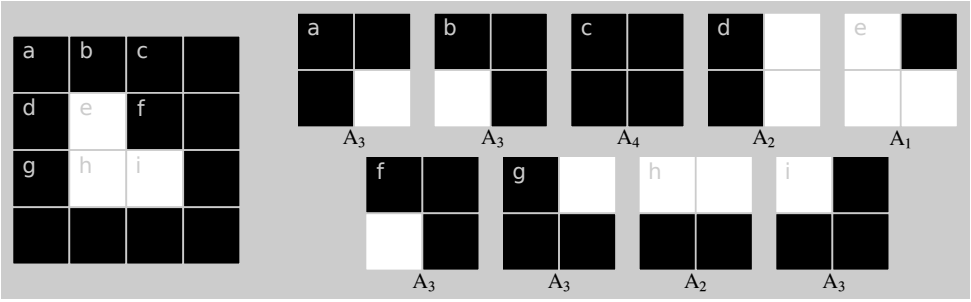


Figure 15: Calcul des fonctionnelles de Minkowski sur une image numérique 2D. Sur l'image de gauche, on compte $M_0 = 3$ (l'aire, en px) ; $M_1 = 8$ (l'interface, en px) ; $M_2 = 1$ (la caractéristique d'Euler). A droite, les 9 blocs de 2×2 voisins au pixel d'ancrage en haut à gauche, dénommé a, b, c, etc. Les bordures droite et inférieure ne sont prises en compte que dans les voisinages des 9 pixels d'ancrage : c'est un effet de bord. En classant les 9 blocs selon les catégories définies Figure 14, et en utilisant les formules (14), on retrouve les valeurs de M_0, M_1, et M_2 attendues.

3.3 Résultats et discussions

3.3.1 Effet de la résolution

Dans cette partie, l'objectif est de comprendre l'effet de la résolution sur les fonctionnelles de Minkowski. Puisque l'introduction de ces grandeurs vise à décrire un champ nuageux physique, dont les propriétés thermodynamiques ou radiatives ne dépendent pas du mode d'observation, il est souhaitable que les fonctionnelles de Minkowski soient insensibles à la résolution.

Afin de répondre à cette question, nous dégradons la résolution d'une image satellite pour observer l'évolution des fonctionnelles de Minkowski (Fig. 16). Comme attendu, la couverture nuageuse m_0 est insensible à la dégradation de la résolution. [4] En revanche, les densité d'interface m_1 et caractéristique d'Euler m_2 varient grandement sur la plage de résolution explorée, pour converger vers 0. On imagine bien, en effet, que dans la limite de basse résolution où l'image est composée d'un unique pixel, il n'existe plus d'interface ni de composante connexe.

Afin de mieux comprendre les asymptote en $m_1 \sim 1/s$ et $m_2 \sim 1/s^2$ mises en évidence dans la figure 16, nous allons examiner le cas limite basse résolution. Dans ce cas, les structures nuageuses sont de l'ordre de la taille des pixels, ou plus petites, si bien que les pixels deviennent quasi-indépendants les uns des autres. Toute dégradation de la résolution engendre une perte d'information sur la morphologie du champ nuageux à décrire.

[4] Pour une raison inconnue, le module DPM tools produisait une tendance linéaire décroissante de m_0. Le courbe de m_0 affichée sur la figure 16 provient du calcul trivial de couverture nuageuse contenu dans le module cloudfield, et non pas de DPM Tools.

Ce cas est illustré sur la figure 17, où les pixels qui composent l'image sont tirés aléatoirement, de manière indépendante. On peut trouver une formule analytique pour la valeur de m_1 dans le cas poissonnien de couverture nuageuse c. Dans une grille de taille $N \times N$ ayant pour résolution s km/px, la longueur totale d'interface possible s'écrit $2N(N-1)s$. Or pour former une interface, il faut que les pixels de part et d'autre soient de couleurs différente. Cet évènement a pour probabilité $2c(1-c)$. Ainsi,

$$m_1 = \frac{M_1}{N^2 s^2} = \frac{2c(1-c) \cdot 2N(N-1)s}{N^2 s^2} \sim \frac{4c(1-c)}{s} \tag{15}$$

Une application numérique à partir d'un champ poissonnien de couverture $c = 0.3$ conduit à la loi de puissance : $m_1 \sim 0.84\, s^{-1}$. Ce résultat théorique est partiellement confirmé par la simulation (Fig. 17), à partir de laquelle une régression linéaire montre que $m_1 \sim 0.66\, s^{-1.00}$. Nous ne sommes pas en capacité l'écart entre la valeur théorique du numérateur, et sa valeur simulée : il pourrait s'agir d'une inadéquation entre les modèles théorique et numérique, d'une coquille théorique, ou d'une coquille numérique en particulier vis-à-vis du module DPM Tools. La tendance simulée de $m_2 \sim 1/s^2$ s'interprète intuitivement ainsi : en dégradant la résolution d'un facteur k, on remplace k pixels par un unique pixel. Or cette surface de k^2 pixels remplacés contenait une densité m_2 de composantes connexes, toutes disparues au profit de l'unique pixel. On remarquera enfin que les lois de puissances obtenues pour m_1 et m_2 sont correctes d'un point de vue dimensionnel.

Le cas contraire – haute résolution, est illustré sur la figure 18 : la forme à décrire est largement plus grande que la taille des pixels. La valeur de la couverture nuageuse m_0 présente une légère tendance décroissante dûe à la déformation des bords du disque. La densité d'interface m_1 est constante, égale au périmètre du disque à la discrétisation près. La valeur de la caractéristique d'Euler M_2 prend une valeur constante égale à 1. Si le champ nuageux est bien résolu, une faible dégradation de la résolution ne détruit ni interface ni composantes connexes.

Il semble donc que l'image satellite originale de la figure 16 soit suffisamment résolue pour ne pas se situer dans le cas limite poissonnien, atteint à partir de 4 km/px. Il est toutefois clair que les fonctionnelles de Minkowski ne sont pas non plus insensibles à la dégradation de la résolution, même faible. Ainsi l'image satellite originale ne se situe pas non plus dans le cas limite de l'objet parfaitement résolu. Une difficulté technique de l'observation *complète* des champs nuageux est que leur taille varie entre quelques mètre et la taille de continents. Il est également important de noter que la notion même de nuage en tant qu'objet aux frontières définies tel le disque pris en cas limite n'est pas évidente. [Lovejoy 1982, Rees et al. 2024] mettent en évidence la fractalité des bordures de nuages, mêmes celles des cumulus qui semblent les plus définies : on trouve des motifs et structures quelle que soit l'échelle d'observation. Il serait intéressant d'étudier le caractère fractal des structures nuageuses à la lumière des fonctionnelles de Minkowski.

Notons finalement que [Armstrong et al. 2019, Fig. 4] propose une autre analyse de sensibilité. Dans cette approche on retire à l'image les composantes connexes – ou *clusters* – de taille de plus en plus importante. Ces clusters ont une contribution positive à la caractéristique d'Euler M_2, indépendante de leur taille. L'étude de sensibilité montre que la valeur de la caractéristique d'Euler M_2 se stabilise une fois que les clusters de taille 10-100 pixels sont retirés. La justification scientifique pour le retrait de ces clusters est toutefois délicate et la transposition de cette méthode d'un champ disciplinaire à un autre n'est pas immédiate.

3.3.2 Effet du seuil

Les fonctionnelles de Minkowski décrivent un système biphasé. La question du choix du seuil ρ est primordiale au moment de binariser une image satellite de niveaux de gris pour décrire le champ nuageux. [K. R. Mecke 1996] est confronté à cette même question du seuil ρ lorsqu'il tente de décrire la morphologies des structures du champ de concentrations en ion I_3^- (voir section 3.1.3). Son approche est la suivante. Il commence par introduire trois variables dérivées des fontionnelles de Minkowski à partir de fonctions

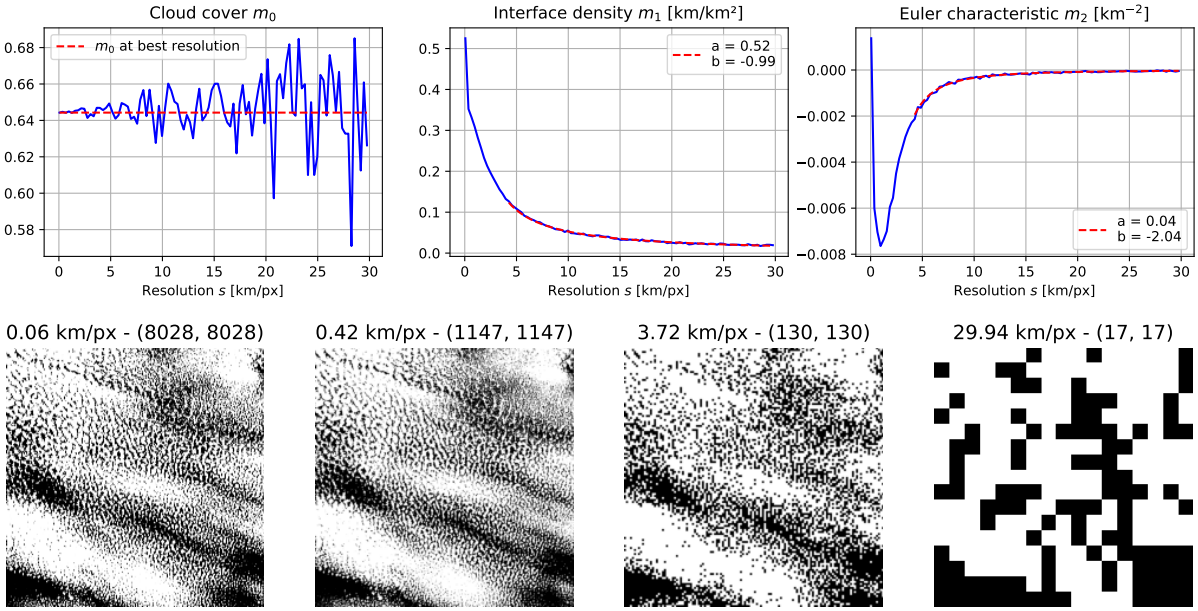


Figure 16: Analyse de sensibilité à la résolution d'une image satellite. Champ nuageux de l'Océan Indien observé par NOAA-20 / VIIRS (NASA Worldview). L'image originale a une résolution de 60 m/px, puis est dégradée en ne gardant qu'un pixel sur deux, puis trois, etc. La valeur seuil est choisie à 150/255. La fonction d'ajustement est détaillée Figure 17.

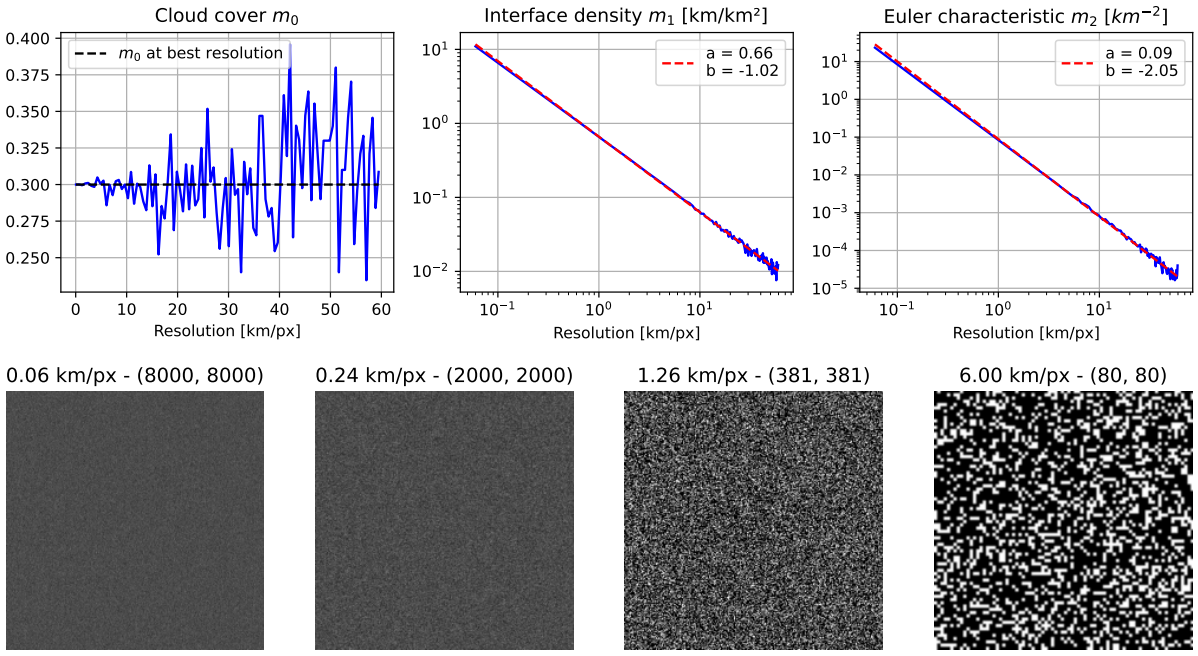


Figure 17: Cas limite poissonnien. Afin de se rapprocher de l'image satellite utilisée Figure 16, la taille de l'image originale est 8000×8000, pour une échelle est arbitrairement choisie à 60 m/px. Tirage poissonnien de couverture nuageuse $c = 0.3$. La dégradation de l'image est effectuée en ne gardant qu'un pixel sur deux, puis trois, etc. La régression linaire réalisée pour m_1 et m_2 est $y = a\,x^b$, soit $\log y = b\,\log x + \log a$.

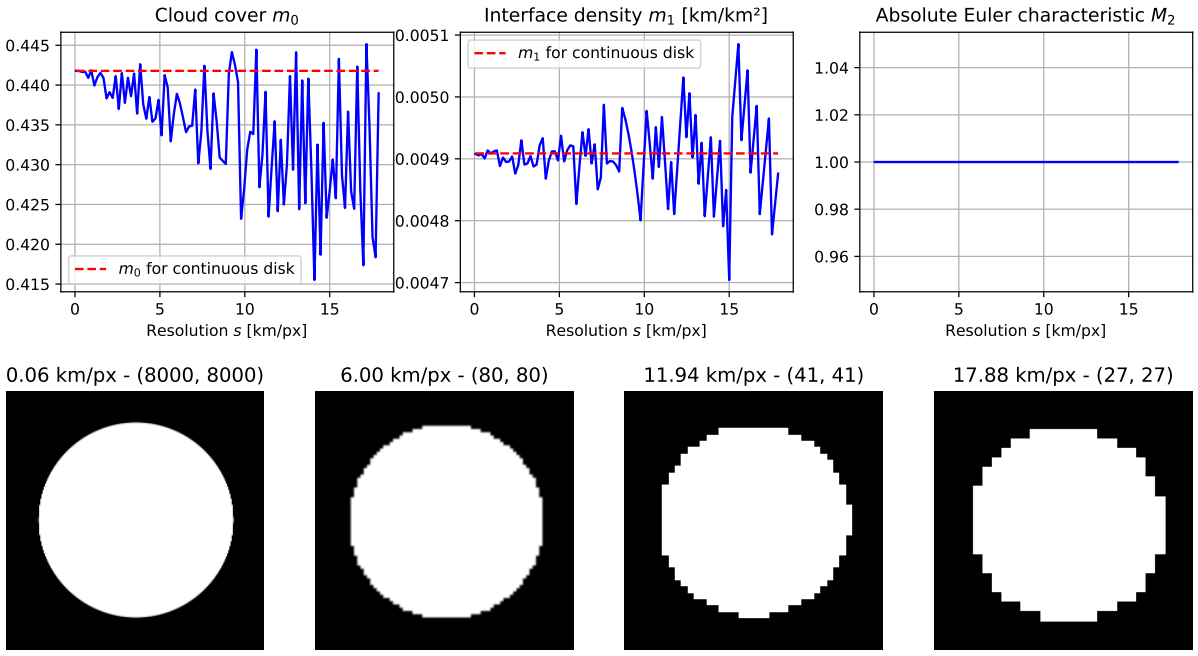


Figure 18: La taille de l'image originale est 8000×8000, pour une échelle est arbitrairement choisie à 60 m/px. Le disque est de rayon 18 km. La dégradation de l'image est réalisée en ne gardant qu'un pixel sur deux, puis trois, etc.

communes en physique, qu'il évalue pour différentes valeurs de seuil ρ :

$$\begin{cases} p_{m_0}(\rho) = \tanh^{-1}(2\,m_0 - 1) \\ p_{m_1}(\rho) = \dfrac{m_1}{m_0\,(1 - m_0)} = 4\,m_1 \cosh^2[p_{m_0}(\rho)] \\ p_{m_2}(\rho) = \dfrac{m_2}{m_1} \end{cases} \tag{16}$$

L'article précise qu'il n'y a pas de lien établi avec les phénomènes sous-jacents, mais que ces fonctions ne fonctionnent qu'avec la réaction étudiée dans [Ouyang and Swinney 1991], sur des données expérimentales et non simulées. Il construit ensuite un jeu de 12 variables qui correspondent aux 4 coefficients du développement polynomial de degré 4 en ρ, où ρ est normalisé pour varier entre -1 et 1, de chacune des trois fonctions de (16). [K. R. Mecke 1996] parvient à tirer des conclusions des valeurs de ces coefficients polynomiaux, vis-à-vis des paramètres expérimentaux (température, concentration en réactifs) et de l'auto-organisation en motifs hexagonal, lamellaire ou turbulent (voir Figure 10).

La figure 19 montre une analyse de sensibilité au seuil de binarisation ρ. La courbe d'évolution de m_0 indique une diminution de la couverture nuageuse avec la valeur seuil ρ. Ce comportement est attendu du fait que pour les valeurs seuil élevées, le nombre de pixels qui les dépassent – donc nuageux – est nécessairement plus faible. Les comportements de m_1 et m_2 se comprennent ainsi : pour $\rho = 0$, le champ nuageux est parfaitement blanc. A mesure que la valeur de ρ augmente, certains pixels deviennent noirs ce qui créée des trous, donc augmentent l'interface m_1 et créent des composantes connexes de valeur négative m_2. Un raisonnement analogue explique la forme de la courbe pour ρ proche de 256.

La méthode proposée par [K. R. Mecke 1996] pour les champs de concentration en ion I_3^- ne fonctionne pas pour nos images satellites. En effet, les polynômes d'ordre 3 se révèlent inadaptés pour décrire les variations des métriques dérivées p_{m_i}. De manière générale, les fonctions m_i et p_{m_i} semblent trop peu régulières pour pouvoir être décrites par des fonctions simples. Là encore se pose la question de savoir si la résolution de l'image originale est suffisante pour tirer des conclusions de la faiblesse de cette méthode.

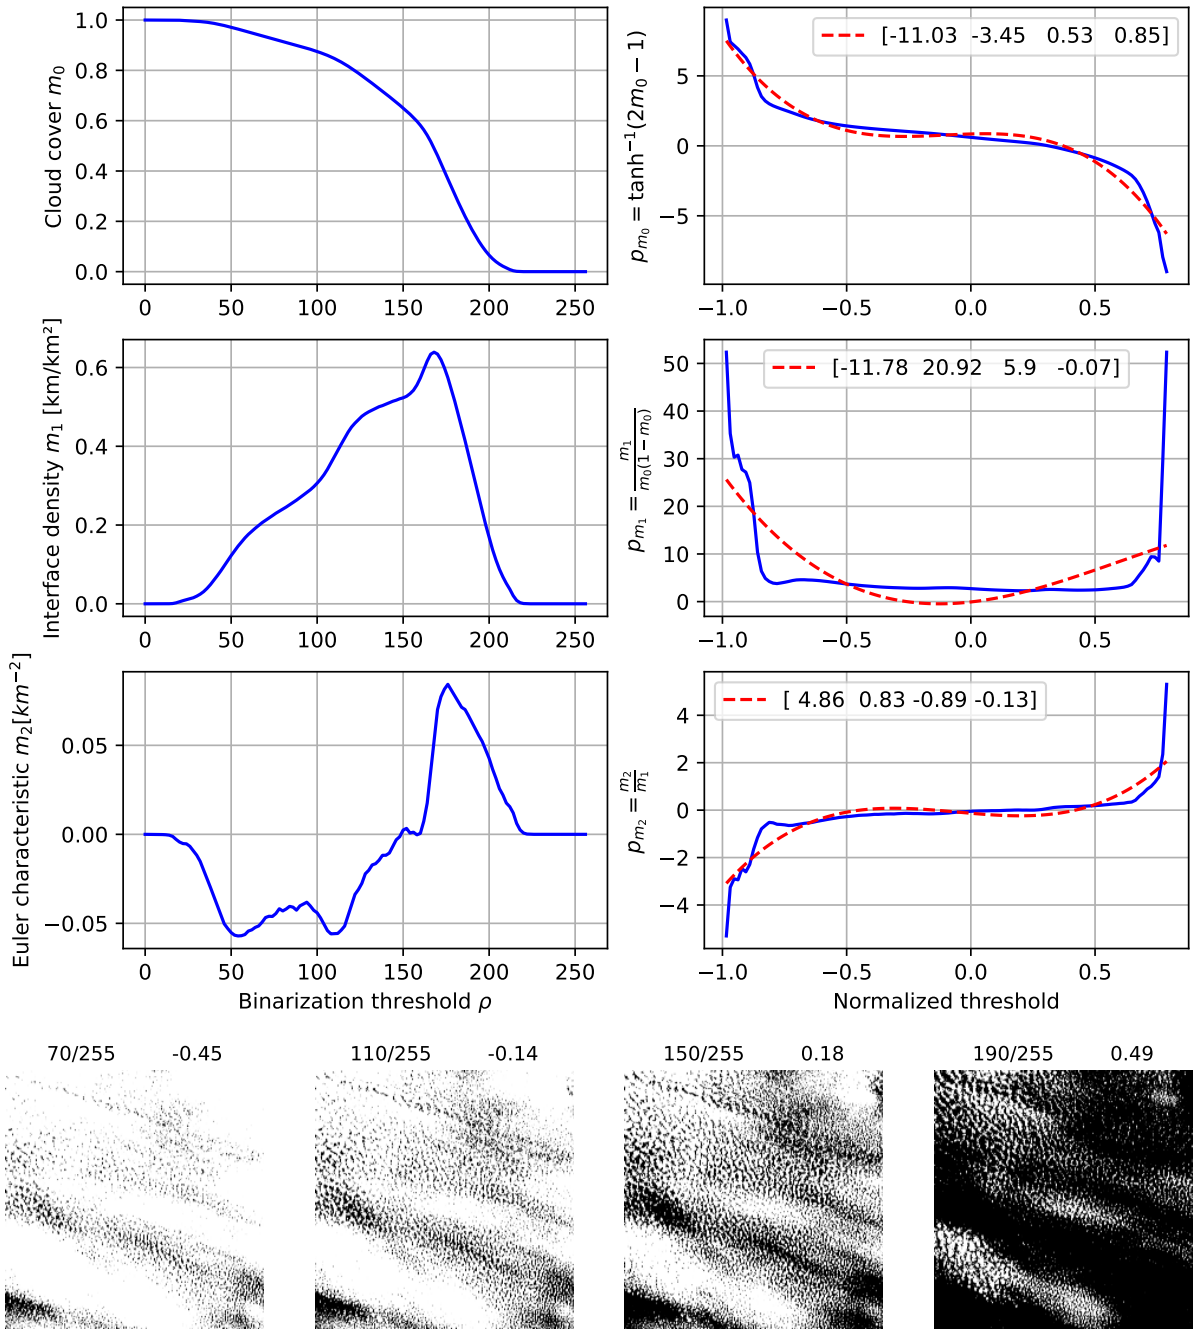


Figure 19: Analyse de sensibilité au seuil de binarisation ρ d'une image satellite. Champ nuageux de l'Océan Indien observé par NOAA-20 / VIIRS (NASA Worldview), de résolution 60 m/px. L'image RGB est d'abord convertie en 256 niveaux de gris puis binarisée à la valeur seuil ρ. En haut à droite, les trois figures montrent les transformations p_{m_0}, p_{m_1} et p_{m_2} introduites à l'équation (16), sur lesquelles on ajuste un polynôme cubique selon la méthode des moindres carrés. Les quatre coefficients $[\ a\ \ b\ \ c\ \ d\ ]$ sont les coefficients du polynôme ajusté $aX^3 + bX^2 + cX + d$.

4 Conclusion

Au cours de ce stage, nous avons tenté de décrire les champs nuageux océaniques méso-échelle en introduisant des mesures d'images satellites binaires – ou masques nuageux. Nous avons proposé deux approches. La première, de nature statistique, s'appuie sur une fonction de corrléation $C(\vec{r})$, inspirée du modèle d'Ising. La seconde, de nature topologique, s'appuie sur les fonctionnelles de Minkowski M_i. L'une comme l'autre des approches prend le parti de symétriser la phase nuageuse et la phase ciel clair, dans la filiation du modèle d'Ising ou d'autres systèmes biphasés.

Nous avons avant tout examiné l'adaptation de ces outils mathématiques continus à des images satellite optiques, ce qui présentait plusieurs défis.

D'abord, la résolution des images. Une analyse de sensibilité à la résolution a permis de montrer que la fonction de corrélation n'est pas sensible à la résolution, et nous avons pu identifier le comportement des fonctionnelles de Minkowski dans les cas parfaitement résolu et poissonnien. La meilleure résolution que nous avons trouvée est celle de l'instrument VIIS, de 400 m, dont nous avons pu extraire de la fonction de corrélation une longueur de corrélation $\ell_c \sim 1.5$ km pour le champ nuageux choisi. L'étude du cycle de vie des champs nuageux nécessiterait toutefois de s'appuyer sur de l'imagerie géostationnaire pour laquelle la résolution est plus grossière (1 à 2 km pour Meteosat Third Generation).

Ensuite, le choix du seuil de binarisation ρ. Dans la mesure où nous souhaitons décrire des champs binaires, il est nécessaire de choisir une valeur de seuil parmi celles qui séparent le champ de nuages de l'océan. Une analyse de sensibilité de la fonction de corrélation semble montrer qu'il est possible d'isoler la structure du champ de l'effet du seuil au moyen d'un ajustement pseudo-exponentiel de la fonction de corrélation. Les fonctionnelles de Minkowski sont quant à elles sensibles à la valeur de seuil, sans qu'on ait pu modéliser vraisemblablement leur comportement. L'enjeu serait donc, à l'avenir, de systématiser le choix du seuil, ou de réaliser des études dynamiques à seuil fixé. Il serait également envisageable de généraliser les mesures introduites dans ce rapport à des champs continus d'épaisseur optique ou de probabilités [Mascaut et al. 2023].

Enfin, l'homogénéité. Les mesures sont réalisées sur des morceaux de ciel de taille finie. Il existe un compromis entre une taille de fenêtre suffisamment grande pour rendre les mesures de corrélation ou de fonctionnelles de Minkowski statistiquement significatives, mais suffisament réduites pour que ces mesures puissent être considérées homogènes sur la fenêtre. Contrairement à d'autres domaines d'application des statistiques spatiales (physique des liquides, galaxies, magnétisme, etc.), il est relativement difficile de trouver des fenêtres qui satisfont ce compromis dans le cas des champs nuageux.

On peut entrevoir plusieurs développement du travail conduit pendant ce stage.

En premier lieu, une fois la soutenance de stage passée, nous entamerons l'écriture d'une publication à partir du présent rapport, afin de proposer les différentes métriques à la communauté scientifique.

Dans la continuité directe du travail mené, il serait bénéfique d'approfondir notre compréhension du vaste domaine des statistiques spatiales, mais aussi de s'inspirer des applications de ces outils dans les autres champs disciplinaires des sciences expérimentales. On pourrait aussi imaginer essayer d'autres métriques.

Une étape indispensable pour mettre en évidence l'utilité des mesures introduites pour décrire les champs nuageux, serait de classer les nuages. L'époque actuelle suggère de s'intéresser aux applications des algorithmes d'apprentissage machine pour mener à bien cette tâche. On pourrait en effet fournir aux algorithmes les mesures associées aux images satellites, et étudier les propositions de classifications générées. Ce travail nécessiterait une large base de données de champs nuageux uniformes, et d'altitude connue. En effet, dans ce rapport, les images satellites ne renseignaient pas sur l'altitude des structures nuageuses observées.

Dans l'éventualité où la reproductibilité de nos mesures serait établie, on peut leur imaginer des applications directes, telles que l'évaluation de modèles numériques de génération de champs nuageux comme [Mascaut et al. 2023], ou encore l'étude du cycle de vie des structures nuageuses. A terme, il serait intéressant d'aboutir à une physique statistique de ces champs nuageux, qui s'appuierait sur nos mesures pour observer la transition d'un type de nuage vers un autre, d'un ciel clair à un ciel nuageux, tout en essayant de les relier aux grandeurs thermodynamiques impliquées en physique des nuages (humidité, température, concentration en aérosols), ou non (entropie thermodynamique comme suggéré dans [Singh and O'Neill 2022]). Une utilisation des fonctionnelles de Minkowski comme grandeurs thermodynamiques est explorée dans [Eder 2018].

Remerciements

Je remercie très chaleureusement Olivier Pujol pour sa disponibilité et son accompagnement pendant ces 5 mois de stage de printemps - été 2026. Je remercie également Jérôme Brioude et Faustine Mascaut pour leurs aides ponctuelles durant le stage. Merci à Philippe Dubuisson et à l'équipe du LOA pour l'accueil qui m'a été réservé. Je remercie Hélène Chepfer, Sébastien Rodriguez et Victor Pellet, responsables du Master 2 SECO pour l'invitation à faire un stage de second semestre et pour avoir gardé un œil sur son bon déroulement. Enfin, je remercie Florent Brien et Jean-Christophe Raut, mes rapporteurs, pour le temps qu'ils consacreront à évaluer mon travail.

We acknowledge the use of imagery from the NASA Worldview application (https://worldview.earthdata.nasa.gov), part of the NASA Earth Science Data and Information System (ESDIS). L'utilisation de l'intelligence articielle dans la rédaction de ce rapport se limite à la traduction du résumé en anglais.

References

Armstrong, Ryan T. et al. (2019). Porous Media Characterization Using Minkowski Functionals: Theories, Applications and Future Directions. *Transport in Porous Media*, **130**, 305–335.

Bischof, J. et al. (1996). Dewetting Modes of Thin Metallic Films: Nucleation of Holes and Spinodal Dewetting. *Physical Review Letters*, **77**, 1536–1539.

Bocquet, Lydéric (2023). *Lecture notes on Statistical Physics*.

Denby, Leif et al. (2022). Characterising the shape, size, and orientation of cloud-feeding coherent boundary-layer structures. *Quarterly Journal of the Royal Meteorological Society*, **148**, 499–519.

Douville, H. et al. (2021). Water Cycle Changes. In Climate Change 2021: The Physical Science Basis.

Eder, Gerhard (2018). The role of Minkowski functionals in the thermodynamics of two-phase systems. *AIP Advances*, **8**, 015127.

Jacobs, Karin et al. (2000). "Dynamics of Structure Formation in Thin Liquid Films: A Special Spatial Analysis". *Statistical Physics and Spatial Statistics*. **554**. 2000, pp. 72–91.

Kostinski, A. B. and A. R. Jameson (2000). On the Spatial Distribution of Cloud Particles. *Journal of the Atmospheric Sciences*, **57**, 901–915.

Larkin, Timothy J. et al. (2014). Analysis of image heterogeneity using 2D Minkowski functionals detects tumor responses to treatment. *Magnetic Resonance in Medicine*, **71**, 402–410.

Lovejoy, S. (1982). Area-Perimeter Relation for Rain and Cloud Areas. *Science*, **216**, 185–187.

Mascaut, Faustine et al. (2023). A 2D Ising-like model for cloud field organization in pristine oceans. *The European Physical Journal Plus*, **138**, 76.

Mecke, K. R. (1996). Morphological characterization of patterns in reaction-diffusion systems. *Physical Review E*, **53**, 4794–4800.

Mecke, Klaus R. (2000). "Additivity, Convexity, and Beyond: Applications of Minkowski Functionals in Statistical Physics". *Statistical Physics and Spatial Statistics*. **554**. 2000, pp. 111–184.

Ouyang, Q. and Harry L. Swinney (1991). Transition to chemical turbulence. *Chaos: An Interdisciplinary Journal of Nonlinear Science*, **1**, 411–420.

Peebles, P. J. E. (2020). *The large-scale structure of the Universe*. 2020.

Rees, K. N. et al. (2024). A global analysis of the fractal properties of clouds revealing anisotropy of turbulence across scales. *Nonlinear Processes in Geophysics*, **31**, 497–513.

Richard, Pablo et al. (2025). Comparing the morphology of molecular clouds without supervision. *A&A*, **696**, A217.

Sengupta, S. K. et al. (1990). Cumulus Cloud Field Morphology and Spatial Patterns Derived from High Spatial Resolution Landsat Imagery. *J. Appl. Meteor. and Clim.*, **29**, 1245–1267.

Sethna, James P. (2021). "Correlations, response, and dissipation". *Statistical Mechanics: Entropy, Order Parameters, and Complexity*. 2021.

Singh, Martin S. and Morgan E O'Neill (2022). The climate system and the second law of thermodynamics. *Rev. Mod. Phys.*, **94** (1), 015001.

Stevens, B. et al. (2020). *Quart. J. Roy. Met. Soc.*, **146**, 141–152.

Stoyan, Dietrich (2000). "Basic Ideas ofSpatial Statistics". *Statistical Physics and Spatial Statistics*. **554**. 2000, pp. 3–21.

Wikipedia (2026). *Boolean model (probability theory) — Wikipedia, The Free Encyclopedia*.

Wood, R. (2012). *Mon. Wea. Rev.*, **140**, 2373–2423.

A Python code documentation

To the present report are attached Python code files and cloud field images.

- The *Nuages* folder contains cloud field satellite images of various type, size, resolution. Most of them come from NASA's Worldwiew web app. The folder also contains cloudfields screenshots from [Stevens et al. 2020].
- The *output_figures* folder stores the figures from the *output_figures.py* Python code.
- *boolean_model.py* is a toy model that Olivier and I tried to explore Minkowski functionals, that wasn't mentioned in the report. It is not very well commented.
- *cloudfield.py* is the core file, it contains the CloudField class. It is well coded, commented, and minimal examples are written in this documentation.
- *img.py* is the module that turns images into Numpy arrays. Also discussed in this documentation.
- *output_figures.py* contains functions. Each function outputs a figure used in this report. Works perfectly.

A.1 `img` module

The `img` module converts `.png` or `.jpg` images into numpy arrays. It was mainly built by the AI DeepSeek. Its dependancies are (1) the `Image` module from the `PIL` package, and (2) the `numpy` package.

```
import img as image
from cloudfield import CloudField

img_path = 'Nuages/cloud_street.jpg'
binary_array = image.image_to_binary_array(img_path, threshold=150)
cf_binary = CloudField(binary_array)

poisson_array = image.poisson_field(size=500, cloud_cover=.5)
cf_poisson = CloudField(poisson_array)

disk_array = image.disk(size=800, r=300, save_path='Nuages/disk_test.png')
cf_disk = CloudField(disk_array, r_max = 100)
```

A.2 `cloudfield` module structure

The Python code takes the form of a module named `cloudfield.py`. It contains a public class named `CloudField`, which delegates heavy computations to private classes. Those private classes are optimized by the decorator `@jitclass` from the `numba` module. This decorator converts Python code into faster, machine code. To this day, this decorator seems quite experimental: not all Python and Numpy methods are supported, and the error messages are very general which makes the code harder to fix.

A.2.1 Parameters

Name	Type	Description	Default
`img`	boolean or float [0,1] array, shape = square	represents the cloud field	
`r_max`	float	largest value for the radii axis (in pixels). might be reset to lower value in order to match `r_step`	`0`

```
img_path = 'Nuages/convective_rolls.jpg'
img_array = image.image_to_binary_array(img_path, threshold=150)
cf = CloudField(img_array, r_max=100)
```

A.2.2 Instance attributes

Name	Type	Description
`img`	boolean array	`img` parameter. shape = square
`size`	int	length of the side of the image (in pixels). `self.size = self.img.shape[0]`
`n_tot`	int	total number of pixels in `img`. `self.n_tot = self.size**2`
`n_cloudy`	int	number of cloudy pixel `self.n_cloudy = np.sum(self.img)`
`n_clear`	int	number of clear-sky pixels `self.n_clear = self.n_tot - self.n_cloudy`
`cloud_cover`	float	cloud cover `self.cloud_cover = self.n_cloudy / self.n_tot`
`r_max`	float	largest value for the radii axis (in pixels) `cf.r_max = cf.r[-1]`. can be smaller than the `r_max` input parameter to match `r_step`
`box_boundaries`	int tuple	`box_boundaries = (x0, y0, size)`. the center pixels are drawn within $[x_0; x_0 + \text{size}[\times[y_0; y_0 + \text{size}[$
`box_img`	boolean array	`img` cropped according to `box_boundaries`
`box_cloud_cover`	float	cloud cover within the box

A.2.3 Methods

- `g`

  The pair correlation function is computed in a manner that is close to its definition – *i.e.* the probability of finding a cloudy cell at a certain distance from an other cloudy cell. It was the first numerical approach that we tried. It takes a lot of time to run and is never used to produce the results shown in the report.

```
1
2   """
3   This method calculates the pair correlation function of the
4   image. The principle is the following: we select a sample of
5   cloudy pixels (i,j) in the image, and calculate the probability
6   of finding a cloudy pixel (k,l) at a distance r from (i,j). To
7   do so we construct a histogram of the number of cloudy pixels
8   over the bins r.
9
10  Parameters:
11  n_draws : int. default = 10000
12      Number of pixels (i,j) that we choose randomly. For each
13      (i,j), we also pick n_draws neighbors (k,l).
14      Global complexity = cloud_cover * n_draws**2
15  r_step : float. default = 2
16      Thickness of the radii bins.
17
18  Returns:
19  mean : float array. shape = (len(self.r),)
20      Pair correlation function of the image, averaged for every r
21      over the (i,j) pixels drawn at random.
22  std : float array. shape = (len(self.r),)
23      Standard deviation of the pair correlation functions.
24  sample : int array. shape = (len(self.r),)
25      Size of the sample for each r. Should be close to n_draws.
26  """
27
28  r, mean, std, sample = cf.g(n_draws=10000, r_step=2)
29
30  margin = std / np.sqrt(sample) * 1.96 # Student 95% interval
31
```

```
fig, ax = plt.subplots()
ax.plot(r, mean)
ax.fill_between(r, mean-margin, mean+margin,
                    alpha=.3, linewidth=0, label='95% confidence')
ax.set_xlabel('Radius r [px]')
ax.set_ylabel('Pair correlation function g(r)')
ax.grid()
ax.legend()
```

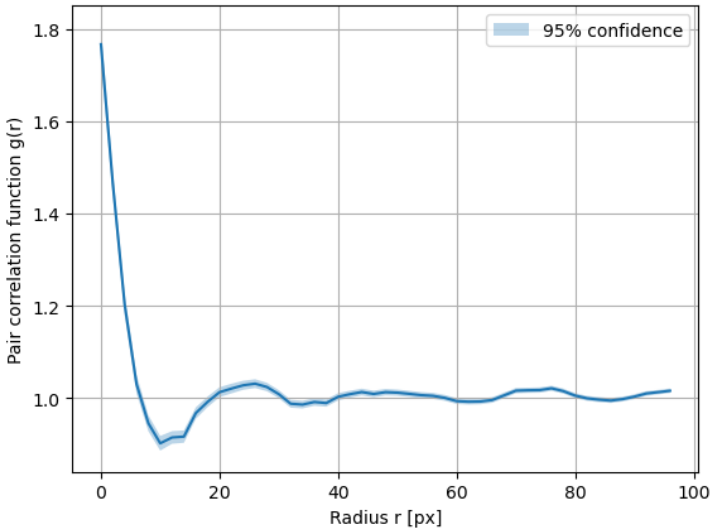


Figure 20: `cf.g()`

- `epsilon`

  Integrates the results of the method `g`. The output of `g` is the input of `epsilon`.

```

"""
Calculates equation (31.9) from Peebles p.145. Epsilon is the
excess cloud cover (in px) within a circle of radius r centered
on a cloudy pixel.

Parameters :
r : float array.
g_mean : float array. shape = (len(r),)
g_std : float array. shape = (len(r),)
g_sample : int array. shape = (len(r),)
    Output arrays from self.g
n_montecarlo : int. default = 100000
    Sample size for Monte-Carlo simulation.

Returns :
eps_mean : float array.
eps_std : float array.
"""

img_path = 'Nuages/convective_rolls.jpg'
img_array = image.image_to_binary_array(img_path, threshold=150)
cf = CloudField(img_array, r_max=100)
r, mean, std, sample = cf.g(n_draws=10000, r_step=2)

```

```
eps_mean, eps_std = cf.epsilon(r, mean, std, sample)
margin = eps_std * 1.96 # Student 95% interval

fig, ax = plt.subplots()
ax.plot(r, eps_mean)
ax.fill_between(r, eps_mean-margin, eps_mean+margin,
                    alpha=.3, linewidth=0, label='95% confidence')
ax.set_xlabel('Radius r [px]')
ax.set_ylabel(r'Excess neighbors $\varepsilon(r)$ [px]')
ax.grid()
ax.legend()

```

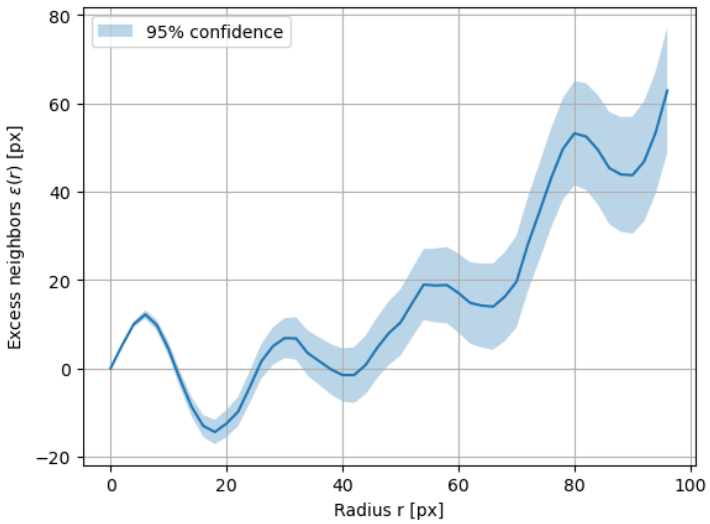


Figure 21: `cf.epsilon()`

- `C`

```

"""
Computes the equal-time spin-spin correlation function (10.1) in
the Oxford book.
We draw n_draws pixels (i,j) within boundary_ij. For each pixel
(i,j), we crop the surrounding cloud field in a square of size
2*r_max, which represents the neighborhood of pixel (i,j).

Parameters:
n_draws : int. default = 100000
    Number of pixels (i,j) that we choose randomly.

Returns:
C_xy : float array
    Spin-spin correlation map.
C_r : float array
    Spin-spin correlation integrated over angles.
C_angle : float array
    Spin-spin correlation integrated over radii.
"""

img_path = 'Nuages/convective_rolls.jpg'
img_array = image.image_to_binary_array(img_path, threshold=150)
cf = CloudField(img_array, r_max=100)
```

```
C_xy, C_r, C_angle = cf.C()

fig, ax = plt.subplots(1, 3, figsize=(16,4))

# Correlation normalization between -1 and 1.
norm=colors.TwoSlopeNorm(vmin=-1., vcenter=0., vmax=1.)

ax[0].imshow(C_xy, cmap='RdBu_r', norm=norm, origin='lower',
                 extent=[-cf.r_max,cf.r_max,-cf.r_max,cf.r_max])
ax[1].plot(C_r)
ax[2].plot(C_angle)

ax[0].set_xlabel(r'$x_x$ [px]')
ax[0].set_ylabel(r'$x_y$ [px]')
ax[1].grid()
ax[1].set_xlabel('Radius r [px]')
ax[1].set_ylabel('C(r)')
ax[2].grid()
ax[2].set_xlabel(r'Angle $\theta$ [deg]')
ax[2].set_ylabel(r'C($\theta$)')

```

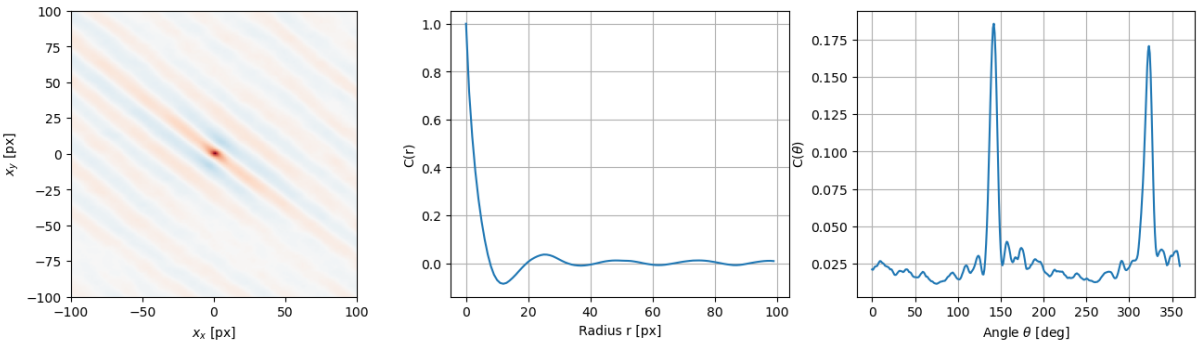


Figure 22: `cf.C()`

- `C_asym`

  Exact same function as C, but cloudy cell is +1 and clear sky cell is 0 instead of +1 and -1.

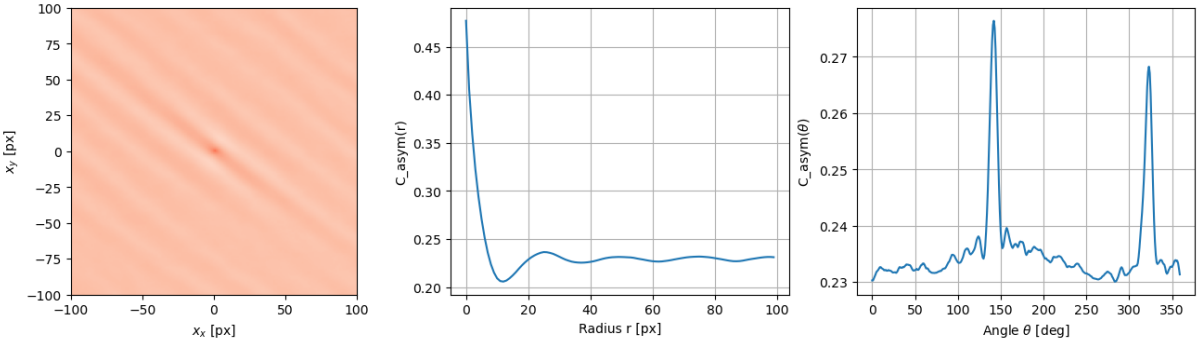


Figure 23: `cf.C_asym()`. The Python code is the same as for method C, except that we compute `C_asym` method instead of `C`, and the colormap is adapted since the asymetric correlation function lies between 0 and 1.

- `minkowski`

Computes the absolute minkowski functionals M0 M1 and M2 using the package DPM Tools, over the whole image (`r_max` is not taken into account), in pixels.

```

img_path = 'Nuages/convective_rolls.jpg'
img_array = image.image_to_binary_array(img_path, threshold=150)
cf = CloudField(img_array, r_max=100)

scale = 60e-3 #km/px
area = cf.size**2 * scale**2

# Minkowski functionals, in pixels
M0, M1, M2 = cf.minkowski()

# Scaling and normalizing
m0 = M0 * scale**2 / area     # km²/km²
m1 = M1 * scale / area        # km/km²
m2 = M2 / area                # 1/km²

```

- `MF_map`

  Testing of the `minkowski_map` function from DPM Tools.